РЕФЕРАТ

Отчет 71 с., 9 табл., 110 источников

ПАРСИНГ, ИЗВЛЕЧЕНИЕ ДАННЫХ, ОБРАБОТКА ЕСТЕСТВЕННОГО ЯЗЫКА, NLP, СЕМАНТИЧЕСКИЙ АНАЛИЗ

Объектом исследований являются алгоритмы по извлечению данных из различных документов и алгоритмы по унификации структуры документов.

Цель работы — разработка библиотеки инструментов для автоматизации процессов парсинга, семантического разбора и выделения структуры в текстовых данных различных форматов.

Результатами работы являются:

1) Библиотека DocuMentor с открытым исходным кодом, доступная через репозиторий GitHub, включающая алгоритмы парсинга PDF и сканов.
2) Экспериментальные исследования по различным подходам для распознания текста, в том числе с помощью больших языковых моделей.

Результаты работ рекомендуется использовать для автоматизации процессов обработки и анализа неструктурированных и слабоструктурированных текстовых данных в различных областях науки и индустрии, где требуется извлечение, анализ и структурирование информации из различных источников.

Область применения включает в себя решение задач по обработке документов, извлечению данных из таблиц, унификации форматов данных и семантическому анализу текстов в различных сферах, включая научные исследования, бизнес-аналитику и обработку больших объемов текстовой информации.

Прогнозные предположения о развитии объекта исследования: дальнейшее развитие библиотеки DocuMentor может включать расширение функциональности для работы с дополнительными форматами данных, оптимизацию существующих алгоритмов, разработку новых методов анализа и структурирования текстовой информации, а также интеграцию с другими инструментами обработки данных и машинного обучения.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 3

1 Литобзор 5

1.1 Основные метрики 5

1.2 Универсальные решения 6

1.3 Обнаружение и распознание текста 34

1.4 Обнаружение элементов документа 39

1.5 Обнаружение и распознание таблиц 42

2 Экспериментальные исследования 45

2.1 Распознание и детекция текста 45

2.3 Распознание таблиц 51

2.4 Распознание документов end2end 52

2.5 Выводы 52

3 Диссеминация проекта 54

ЗАКЛЮЧЕНИЕ 55

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 57

ВВЕДЕНИЕ

Стремительный прогресс в области искусственного интеллекта и машинного обучения значительно увеличил объем обрабатываемых данных. Тем не менее, подготовка данных остается одним из самых трудоемких этапов, на который часто уходит до 80 % времени проекта. Эта проблема особенно остро стоит при работе с неструктурированным и полуструктурированным текстом, таким как документы, электронные таблицы и файлы журналов.

По мере усложнения моделей возрастает потребность в методах, которые автоматически или полуавтоматически идентифицируют структуры данных и извлекают/инкапсулируют содержимое составляющих их элементов из неструктурированного текста. Это важно, как для обучения новым моделям, так и для тонкой настройки существующих, включая большие языковые модели (LLM).

Аннотации, создаваемые вручную, плохо масштабируются, особенно при работе с сотнями миллионов текстов. Человеческие ресурсы ограничены, и даже в рамках схем и представлений одной предметной области требуются значительные усилия. В условиях продолжающейся цифровой трансформации обработка устаревших архивов и каталогов, содержащих накопленную информацию в различных текстовых форматах, стала критически важной задачей.

В рамках проекта “ДокуМентор: библиотека когнитивного парсинга документов с помощью языковых моделей” нашей целью является создание комплексной библиотеки программного обеспечения, способной автоматически или полуавтоматически идентифицировать структуры данных в текстовых представлениях и извлекать информацию для последующего хранения в базе данных.

Ключевым аспектом работы является использование современных методов обработки естественного языка для повышения эффективности и универсальности алгоритмов, включая передовые методы семантического понимания анализируемых объектов.

Были выполнены следующие основные задачи:

1) Библиотека была переработана: основные структуры данных и интерфейсы были переработаны для обеспечения совместимости с LangChain.

2) Был проведен обзор существующие решений для распознавания текста - как классические методы распознавания текста, так и подходы на основе LLM

3) Были проведены многоязычные эксперименты с наборами данных FUNSD и XFUND для оценки качества распознавания, а также комплексные эксперименты по распознаванию всего документа и таблиц.

4) Был реализовал алгоритм парсинга PDF и сканов основываясь на результатах экспериментальных исследований в DocuMentor.

Внедренные компоненты были интегрированы в библиотеку DocuMentor с открытым исходным кодом, которая предоставляет инструменты и алгоритмы для частичной или полной автоматизации синтаксического анализа для последующих задач, таких как анализ данных, машинное обучение и генерация данных с расширенным поиском. Дополнительные модули будут формализованы и выпущены на последующих этапах проекта.

1 Литобзор

В этом разделе отчета рассматриваются ключевые задачи, решаемые в рамках оптического распознавания символов (OCR). Мы начнем с обзора фундаментальных и универсальных показателей, применимых к широкому кругу задач, затем перейдем к конкретным задачам: обнаружению и распознаванию печатного и рукописного текста, анализу макета документа (Layout Detection), обнаружению и распознаванию структурированных данных и сквозному пониманию документа. Каждый подраздел содержит краткое описание проблемы, обзор соответствующих моделей и подходов, ссылки на исследовательские работы и хранилища с открытым исходным кодом, а также специализированные показатели оценки, где это применимо.

1.1 Основные метрики

OCR-конвейер решает две взаимосвязанные подзадачи — локализация (обнаружение фрагментов изображения, содержащих текст или другие логические элементы) и распознавание (преобразование изображения в последовательность символов/слов) [1]. В основном можно выделить две группы метрик: для оценки качества локализации и для оценки качества распознавания. Для локализации используются метрики, основанные на пересечении-объединении (IoU) такие, как F1@50, Precision и Recall [2] (Таблица 1.1). Самыми распространёнными метриками для оценки качества распознавания текста являются CER и WER, которые измеряют количество ошибок символов и слов соответственно [3][4]. Дополнительно применяются CER_{norm} и WER_{norm} — варианты, в которых текст предварительно нормализован (нижний регистр, удалена пунктуация, лишние пробелы) [5] (Таблица 1.2).

CER и WER надёжно отражают качество на небольших фрагментах текста (слово, строка); для длинных документов используют усреднение значений, вычисленных по отдельным строкам [4].

Таблица 1.1 — Основные метрики для оценки качества локализации

Обозначение	Формула (для одного изображения)	Пояснение
IoU (Intersection-over-Union)	$IoU = \frac{\lvert B_{pred} \cap B_{gt} \rvert}{\lvert B_{pred} \cup B_{gt} \rvert}$	Мера перекрытия, предсказанного Bounding-Box B_{pred} и эталонного B_{gt}
Precision	$P = \frac{TP}{TP + FP}$	Доля предсказанных боксов, попавших в «правильные» (IoU ≥ τ).
Recall	$P = \frac{TP}{TP + FN}$	Доля эталонных боксов, которые модель успешно нашла.
F1@50	$F1@50 = \frac{2PR}{P + R}$, при $IoU \geq 0.5$	Гармоническое среднее Precision и Recall при пороге IoU = 0.5.

Таблица 1.2 — Основные метрики для оценки качества распознавания

Обозначение	Формула	Пояснение
CER (Character Error Rate)	$CER = \frac{S + D + I}{N}$	S — число заменённых символов, D — удалений, I — вставок; N — длина эталонной строки в символах
WER (Word Error Rate)	$WER = \frac{S_\omega + D_\omega + I_\omega}{N_\omega}$	Аналог CER на уровне слов.
CER_{norm} / WER_{norm}	**CER/WER после нормализации строки (нижний регистр, без пунктуации и лишних пробелов).**	Применяют, когда регистр и пунктуация несущественны для downstream-задачи.

1.2 Универсальные решения

В последние годы растет интерес к универсальным крупномасштабным моделям и интегрированным платформам, способным выполнять несколько задач одновременно. Такие подходы могут сочетать обнаружение текста, распознавание текста, анализ макета документа, обнаружение таблиц и другие функциональные возможности в рамках единой архитектуры. В этом обзоре мы рассмотрим несколько из этих моделей, которые являются перспективными для приложений распознавания текста. Сравнительный анализ их

производительности и практического использования в конкретных сценариях будет представлен в соответствующих разделах отчета.

Donut

Donut (Document Understanding Transformer) — это модель понимания документов без распознавания текста, разработанная компанией NAVER CLOVA (2022). Он сочетает в себе визуальный кодер на основе Swin-Transformer и текстовый декодер на основе BART для прямого преобразования изображения документа в структурированную последовательность токенов (например, JSON или Markdown), устраняя необходимость во внешнем движке распознавания текста [6]. Donut обеспечивает производительность, сопоставимую или превосходящую традиционные конвейерные подходы (например, "детектор + распознаватель") в задачах классификации документов (RVL-CDIP), синтаксического анализа форм (FUNSD, CORD) и визуального ответа на вопросы (VQA) [6][7]. Модель предварительно обучена на большом синтетическом наборе данных SynthDoG, охватывающем приблизительно 38 языков, что позволяет эффективно обобщать различные макеты документов [6]. Для последующих приложений Donut настраивается с помощью обучения на основе инструкций: желаемый формат вывода задается с помощью подсказки, а тонкая настройка выполняется на нескольких сотнях примеров с аннотациями. Для этого процесса требуется приблизительно 16 ГБ видеопамяти, что делает его возможным на графических процессорах среднего класса [7][8]. Благодаря своему авторегрессионному декодеру Donut может генерировать выходные данные в любом текстовом формате — чаще всего это JSON (с полями формы), таблицы Markdown или текст произвольной формы. Желаемая структура вывода определяется с помощью специальных токенов в командной строке [6][9]. Исходный код и предварительно настроенные веса (включая donut-base и donut-large) доступны в открытом доступе по лицензии MIT на GitHub [9]. Предварительно подготовленные контрольные точки (например, donut-base-finetuned-rvlcdip) также размещены в Hugging Face Hub [8], что обеспечивает неограниченное локальное развертывание. Что касается производительности, Donut обрабатывает страницу за 50-150 мс на графическом процессоре T4 (в среднем ~0,08 с в исходном тесте), что примерно в 20 раз быстрее, чем системы на основе LayoutLM (1,5-1,7 с). При этом достигается точность 94,5 % на RVL–CDIP и улучшение на 2-4 процентных пункта в Формуле-1 забивают по FUNSD [6][7]. Вариант на базе donut содержит около 110

миллионов параметров. Для вывода с точностью FP16 требуется графический процессор с объемом видеопамяти около 8 ГБ; для точной настройки обычно требуется около 16 ГБ видеопамяти [8]. Языковая поддержка охватывает примерно 38 языков, включая русский и китайский, благодаря предварительной подготовке на многоязычном синтетическом корпусе. Добавление новых языков возможно путем создания синтетических данных с последующей краткой доработкой [6].

DiT

DiT (Document Image Transformer) — это кодировщик на основе vision transformer, предназначенный для извлечения макета документа и визуальных элементов. Он служит основой для систем искусственного интеллекта документов и не выполняет распознавание напрямую — нижестоящие компоненты, такие как Mask R-CNN или Cascade R-CNN, подключены для прогнозирования категорий блоков [10]. Этот чисто визуальный подход, дополненный масштабной предварительной подготовкой под самоконтролем, обеспечивает точность, сравнимую с мультимодальными методами [10]. DiT предварительно обучен более чем 11 миллионам сканирований документов без маркировки из IIT-CDIP, используя задачу маскированного прогнозирования на основе исправлений, не полагаясь на текстовые метки или результаты распознавания [10]. Такое самостоятельное обучение позволяет модели фиксировать пространственные закономерности, такие как расположение текста, таблиц и иллюстраций. Для последующих приложений авторы рекомендуют проводить тонкую настройку на целевых наборах данных (например, DocLayNet, FUNSD, PubLayNet), что неизменно улучшает mAP по сравнению с обучением с нуля [10]. Выходные данные DiT состоят из векторов объектов на уровне изображений. Структурные выходные данные (JSON, HTML, CSV) или текстовое содержимое получаются только с помощью дополнительных средств обнаружения или декодирования; базовая модель DiT не генерирует структурированные форматы изначально [10]. Исходный код и контрольные точки доступны в репозитории microsoft/dit на GitHub [11]. Популярный вариант, *dit-base-960k*, размещен на Hugging Face Hub [12] и может быть доработан с помощью библиотеки Transformers. В PubLayNet DiT в сочетании с Cascade R-CNN обеспечивает отображение 94,9 %, превосходя предыдущие методы (~91 %), при этом прирост в таблицах и текстовых блоках превышает 2 процентных пункта [10]. При автономной обработке DiT-Large + Cascade R-CNN работает со скоростью около 6 кадров в секунду на NVIDIA A100 емкостью

80 ГБ [13], что медленнее, чем у моделей, подобных YOLO, но достаточно для пакетной обработки. Для контрольной точки DiT-Base-960k (~86 миллионов параметров) требуется около 7 ГБ памяти графического процессора при разрешении ввода 224×224 пикселей; более крупные варианты (Large/XL) линейно масштабируются по объему памяти и времени вывода [12]. Поскольку DiT работает исключительно с визуальными элементами, он по своей сути не зависит от языка. Его эффективность при работе с многоязычными документами была подтверждена экспериментально [10]. Поведение, зависящее от языка, определяется подключенным устройством для декодирования текста или головкой распознавания.

GOT-OCR2.0

GOT (General OCR Theory) 2.0 — это унифицированная модель-трансформер кодера-декодера (~580 миллионов параметров), которая одновременно локализует и распознает текст, воплощая парадигму "OCR-2.0" [14]. Компактный визуальный кодировщик с высокой степенью сжатия преобразует целые изображения документа в скрытые векторы, в то время как авторегрессионный декодер с длительным контекстом генерирует обычный текст или структурированные аннотации по запросу. Модель обрабатывает как полностраничные документы, так и обрезанные области и поддерживает интерактивные подсказки, такие как координаты областей, выходные форматы или стилистические указания [14]. Предварительная подготовка проводилась на смешанном реальном и синтетическом корпусе, охватывающем широкий "алфавит" символов в различных областях, включая печатный текст, математические формулы, химические структуры, нотную запись и таблицы. В документе описывается обучение английскому и китайскому языкам, где модель обеспечивает самую современную производительность; архитектура не зависит от языка и может быть точно настроена на основе любых языковых данных [14]. Форматы вывода включают обычный текст, Markdown (с таблицами), LaTeX, SMILES, TikZ и другие структурированные представления для формул и диаграмм. Желаемый формат указывается с помощью специальных маркеров в текстовом приглашении [15]. Исходный код, веса моделей и примеры логического вывода доступны в официальном репозитории GitHub по открытой лицензии [15]; методология подробно описана в препринте на arXiv [14]. В тесте FOX для PDF-документов модель достигает F₁ = 92,6 % (EN) и 92,8 % (ZH) на уровне word, превосходя Qwen-VL (параметры>72B, 88 %). Частота

символьных ошибок (CER) невелика и составляет 0,11 (EN) и 0,096 (ZH). Логический вывод с несколькими кадрами повышает точность обработки небольших элементов в сложных макетах; в ряде задач GOT-OCR 2.0 приближается по производительности к GPT-4V [14]. Для вывода полной модели требуется один графический процессор с примерно 16 гигабайтами видеопамяти; 8-битное квантование позволяет использовать графические процессоры потребительского класса [15]. Модель была обучена и апробирована на английском и китайском языках, но демонстрирует высокую производительность на латинице, кириллице и логографических шрифтах. При наличии соответствующих данных ее можно распространить на более чем 60 языков [14].

PaddleOCR

PaddleOCR — это платформа распознавания текста с открытым исходным кодом, разработанная Baidu, объединяющая облегченные серверные модели для обнаружения текста (DB, RT-DETR, PicoDet), распознавания (CRNN, SVTR, PP-OCRv4 rec) и модули постобработки (ориентация, исправление, формулы, штампы). Подсистема PP-Structure обеспечивает структурный анализ документов, включая определение структуры, извлечение таблиц и информации о ключах и значениях. Для таблиц используется конвейер TableMASTER:

1) Определение границ таблицы;

2) Прогнозирование структуры строк и столбцов с использованием эталонной модели;

3) Определение строк с помощью DB или PSENet;

4) Распознавание текста на уровне ячеек с использованием той же основной модели с выравниванием ячеек [16][17].

В версии 2.9 (апрель 2025 г.) были представлены полностью сквозные конвейеры Layout Parsing v2 и PP-ChatOCRv4-doc, преобразующие PDF-файлы и отсканированные документы в Markdown или JSON за один вызов, включая порядок чтения, таблицы и штампы [18][19]. Базовые модели обучаются на основе сочетания общедоступных наборов данных (ICDAR, PubLayNet) и собственных данных; распознавание использует самоконтролируемое обучение и синтетические данные. TableMASTER был разработан для конкурса ICDAR-2021 по разбору научной литературы (задача B), в котором задача была разбита на четыре подзадачи для улучшения обобщения и уменьшения необходимости в

тщательной настройке [17]. Layout Parsing v2 и PP-Structure поддерживают тонкую настройку отдельных компонентов на основе пользовательских данных, а обучающие скрипты доступны в PaddleX [19]. Выходные форматы включают:

- PP-OCR v4: обычный текст + ограничивающие рамки;
- PP-Structure/PP-StructureV2: иерархический HTML/Word;
- TableMASTER: HTML-таблицы (конвертируемые в CSV/JSON) [17];
- Версия для разбора макета 2: Markdown/JSON (с дополнительным bbox) [19];
- PP-ChatOCRv4-doc: пары Markdown/JSON + ключ-значение для KIE с поддержкой многостраничных PDF-файлов в потоковом режиме [18]. Исходный код, предварительно подготовленные веса и сценарии логического вывода доступны на GitHub под лицензией Apache 2.0 [20]; документация и бинарные модели размещены на веб-сайте PaddleOCR [14z][18]. Основные характеристики производительности:
- TableMASTER: 2-е место в финале ICDAR-2021 (TEDS = 96,32 %) и 96,76 % в PubTabNet [17][2];
- PP-OCRv4-сервер: обнаружение на 4,9 % и точность распознавания на 2 % выше, чем в версии 3; мобильная версия ускоряет логический вывод с точностью до 10 % по тексту сцены [18];
- PP-StructureV2: точность структуры таблицы +6 % при той же скорости [21];
- Разбор макета версии 2: RT-DETR-L обеспечивает отображение mAP = 90,4 % за 34 мс (на графическом процессоре); полное преобразование страницы формата A4 в Markdown на NVIDIA T4 занимает ~180 мс [19]. Эффективность использования ресурсов: оптимизация PP-LCNet + SLAHead ускоряет логический вывод в 11 раз без потери качества. Модели обнаружения и распознавания работают на графических процессорах с 4-6 ГБ видеопамяти или на центральном процессоре [22]. Размеры моделей варьируются от 4,8 м (компоновка PicoDet-S) до 123 м (RT-DETR-L). Для полного конвейера PP-ChatOCRv4-doc требуется один графический процессор объемом 16 ГБ (или CPU, который работает в ~2 раза медленнее) [19]. Поддерживаемое аппаратное обеспечение включает графические процессоры NVIDIA, Kunlun XPU и Ascend NPU; модели могут быть экспортированы в ONNX/OpenVINO для периферийного развертывания [18]. Языковая поддержка: PP-OCRv4 поддерживает более 80 языков; модель rec_doc охватывает 15 000 китайских иероглифов, что на ~ 3 процентных пункта ниже частоты ошибок в редких иероглифах. Извлечение

структуры таблицы не зависит от языка, в то время как текст ячейки распознается с использованием языковых моделей распознавания текста [14z][18].

Семейство моделей Qwen

Qwen (Alibaba Cloud) за два года превратилась из текстовой LLM-платформы в полноценную серию мультимодальных моделей визуального языка (VLM), конкурирующих с GPT-4V в задачах распознавания текста.

- Qwen 1 (2023) — открытый двуязычный (zh-en) LLM с параметрами 7B/14B; благодаря обширной предварительной подготовке к работе с PDF-документами, даже первая версия достигла CER ≈8-10 % без специальной предварительной обработки [23].
- Qwen-VL (февраль 2024) — первый вариант языка vision, сочетающий в себе замороженный ViT-кодер и Qwen-декодер. Он принимает полностраничные изображения и выводит Markdown/HTML с пространственными координатами, обеспечивая CER ≈6-7 % для многоязычных документов [24].
- Qwen 2 / 2.5 (сентябрь–декабрь 2024 г.) — улучшена функция токенизации и обучения данных; Qwen 2.5-VL с поддержкой Window Attention стала лидером среди открытых VLM, достигнув 90 % F1 в DocVQA и ChartQA, средний CER ≈5 %, благодаря устойчивости к рукописному вводу и формулам. [25].
- Qwen 3 (апрель 2025, пока только текстовый) - вводит "гибридное мышление". Разработчики объявили, что версия VLM будет выпущена "в ближайшие месяцы", что потенциально повысит точность распознавания текста еще на 1-2 процентных пункта и расширит языковую поддержку (согласно пресс-релизу Alibaba Cloud от апреля 2025 года).

Все поколения Qwen обеспечивают превосходную производительность распознавания текста из коробки благодаря тщательной предварительной подготовке корпуса PDF. На данный момент Qwen 2.5-VL (7B) остается оптимальным выбором для многоязычного распознавания текста [25]. Специализированные варианты с тонкой настройкой, такие как RolmOCR [26] и olmOCR [27], предлагают различные компромиссы в скорости, использовании видеопамяти и встроенных утилитах для пакетной обработки PDF-файлов. Ожидается, что ожидаемый к концу 2025 года выпуск Qwen 3-VL еще больше укрепит лидерство семейства в области распознавания текста с открытым исходным кодом.

Qwen-2.5-VL

Qwen 2.5-VL - флагманский мультимодальный LLM из серии Qwen от Alibaba (конец 2024-2025 гг.) [25]. Он сочетает в себе переработанный кодер Vision Transformer с Window Attention и языковой декодер Qwen, обеспечивая динамическую обработку изображений произвольного размера при сохранении точной пространственной локализации. Модель может извлекать и локализовывать текст, интерпретировать таблицы и формы, анализировать диаграммы и генерировать структурированные выходные данные в HTML, JSON или Markdown [25]. Обучение проходит по двухэтапной схеме: (1) предварительная тренировка с использованием визуального контраста на основе смешанного набора изображений и аннотированных PDF-документов со структурой макета; (2) тонкая настройка инструкций. Веса модели устанавливаются в диапазоне от ~3B до 72B параметров с почти линейной масштабируемостью кодера в зависимости от количества фрагментов изображения [25]. Выходные форматы включают фирменный QwenVL-HTML с семантическими тегами (`<h*>`, `<p>`, `<table>`) и атрибутами `data-bbox` для координат блоков, а также JSON (ключ-значение, формы, таблицы) и Markdown. Все выходные данные автоматически генерируются одним текстовым декодером без внешней постобработки распознавания текста [25]. Исходный код и контрольные точки (3B, 7B, 14B, 32B, 72B) находятся в открытом доступе под лицензией Apache 2.0 в репозитории GitHub QwenLM/Qwen2.5-VL [23]. Представление:

- Версия 72B совместима с GPT-4 Vision и Claude 3.5 Vision на DocVQA, ChartQA и LLaVA-Bench-Doc, обеспечивая до 90 % F1 при добыче в полевых условиях [25].
- При работе со сложными многоязычными документами он достигает CER ≈4-5 % и точно выводит ограничивающие рамки или координаты точек для локализации текста [25].
- Версия 7B превосходит сопоставимые открытые модели в CER/WER для счетов-фактур, форм и отчетов [25]. Требования к ресурсам:
- 7B: 1× RTX 4090 объемом 24 ГБ (fp16)
- 14B: 1× A100 объемом 40 ГБ (fp16)
- 72B: 4× A100 по 80 ГБ или 2× H100 по 80 ГБ с 8-битным квантованием [25]. Языковая поддержка включает китайский, английский, испанский, французский и около 15 других языков. Модель обрабатывает латиницу, логографические символы, рукописный текст и сохраняет структуру при распознавании математических и химических формул [25].

Семейство моделей InternVL3

InternVL3 – это третье поколение мультимодальных моделей от OpenGVLab/Shanghai AI Lab (выпущено в апреле-мае 2025 года), построенное на архитектуре ViT-MLP–LLM: автономный визуальный кодер (InternViT, 300M или 6B) подключен к языковой модели (Qwen 2.5 0.5-72B или InternLM3-8B) с помощью проектора MLP. Ключевые нововведения включают встроенную мультимодальную предварительную подготовку (унифицированную предварительную подготовку по тексту и мультимодальным данным), кодирование визуальных позиций с переменной скоростью (V2PE) для длительных визуальных контекстов, оптимизацию смешанных предпочтений (MPO) и масштабирование во время тестирования с помощью VisualPRM. Семейство моделей включает в себя варианты параметров 1B, 2B, 8B, 9B, 14B, 38B и 78B. Он поддерживает ввод нескольких изображений и видео, а также расширенные сценарии, такие как задачи агента с графическим интерфейсом, промышленные изображения и 3D-восприятие [28][29][30]. Обучение проходит по единой, нативной мультимодальной схеме, на которой все параметры совместно оптимизируются на основе большого объема текста и мультимодальных данных (изображение-текст, видео-текст, чередующийся контент), что устраняет необходимость в отдельном согласовании модальностей. За этим следует последующее обучение: контролируемая точная настройка (SFT), MPO (параметры смешивания, качество и потери при генерации) и масштабирование во время тестирования (наилучшее из возможных с помощью VisualPRM-8B critic). Исследования по удалению подтверждают повышение производительности благодаря V2PE и MPO в большинстве тестов [28][30]. Выходные данные генерируются в виде текста произвольной формы (формат диалога, совместимый с завершениями чата OpenAI при развертывании с помощью LMDeploy). Для наглядного обоснования используются специальные встроенные теги: "<ref>...</ref>" и "<box>...</box>" (нормализованные координаты). Аннотации к набору данных и диалогу представлены в формате JSONL. Модель поддерживает ввод нескольких изображений и потоковый вывод [31][32][33]. Исходный код доступен на GitHub (Openglab/InternVL); полный набор контрольных точек (от 1B до 78B) размещен на Hugging Face и ModelScope. Документация доступна на ReadTheDocs. Доступен бесплатный InternVL-чат API, и большинство карточек моделей выпущены под лицензией Apache 2.0 [34][29][35][36][37]. Производительность: InternVL3-78B достигает 72,2 балла в MMMU,

что является новым достижением среди открытых MLLM. MPO дает до 4-5 баллов за задачи с мультимодальным рассуждением. В OpenCompass серия InternVL3 лидирует среди открытых моделей как с точки зрения восприятия, так и с точки зрения логического мышления. Также сообщается о значительных улучшениях в распознавании текста, понимании диаграмм и документов, многокадровом восприятии видео, графическом интерфейсе и пространственном мышлении [28][29]. Размеры моделей: 1B (~1,8 ГБ), 2B (~4,2 ГБ), 8B (~15,9 ГБ), 9B (~18,3 ГБ), 14B (~30,2 ГБ), 38B (~76,8 ГБ), 78B (~152 ГБ). Поддерживает bf16/fp16 и 8-битное/4-битное квантование (BNB); однако 4-битное квантование не рекомендуется для конфигураций с InternViT-6B из-за снижения производительности. LMDeploy поддерживает тензорный параллелизм: 38B с `tp=2`, 78B с `tp=4` (REST API, совместимый с OpenAI). На практике: 1–2B работают на обычных графических процессорах (≥8-12 ГБ видеопамяти), 8–9B - на 24 ГБ (или 8-разрядных - на 16 ГБ), 14B - на 32-40 ГБ; 38B/78B требуют установки нескольких графических процессоров (например, 2×/4× 80 ГБ в bf16), или может быть запущен в 8-разрядном режиме [30][33][32]. Модель поддерживает несколько языков (включая английский и китайский); в оценки включен раздел о многомодальном понимании на нескольких языках, а карточки модели помечены как "многоязычные" [30][35].

Семейство моделей Ovis

Ovis — это семейство открытых мультимодальных LLM, разработанное командой Alibaba AIDC-AI и развивающееся с 2024 года (Ovis 1.0/1.5/1.6) и расширена в 2025 году за счет Ovis 2, Ovis 2.5 и унифицированной серии Ovis-U1. Основным архитектурным новшеством является структурное согласование визуальных и текстовых представлений: в visual encoder добавлена обучаемая таблица визуального встраивания, позволяющая генерировать “визуальные токены” аналогично текстовым токенам [38]. Ovis 2.5 представляет ViT с собственным разрешением (NaViT) и “режим мышления” для рефлексивного рассуждения. Модель поддерживает ввод одного или нескольких изображений и видеосигнала. Варианты моделей включают в себя: Ovis 2 (1B, 2B, 4B, 8B, 16B, 34B), Ovis 2.5 (2B, 9B) и Ovis-U1 (3B), последний поддерживает генерацию изображений, редактирование и мультимодальное понимание в единой среде [39][41][42][43]. Обучение Ovis 2.5 проходит по пятиэтапной учебной программе: (i) визуальная предварительная подготовка; (ii) мультимодальная предварительная подготовка; (iii) доработка инструкций; (iv) DPO по

предпочтениям в отношении мультимодальных перевозок; (v) обучение с подкреплением и проверяемыми вознаграждениями (GRPO/RLVR). Для глубокого осмысления в процессе обучения используется цепочка рассуждений (CoT) и данные о стиле мышления, помеченные тегом “<think>...</think>”, в сочетании с мультимодальной упаковкой данных и гибридным параллелизмом для ускорения обучения. Основой LLM в Ovis 2.5 является Qwen3; визуальным интерфейсом является NaViT, инициализированный из SigLIP2 **[42]**. Выходные данные включают текстовые ответы (Markdown, JSON) на мультимодальные запросы с потоковой генерацией и дополнительным “режимом мышления” (этапы внутреннего рассуждения, управляемые с помощью параметров логического вывода). Шаблоны диалогов совместимы с дополнениями к чату в стиле OpenAI с помощью vLLM или Transformers; вводимые изображения помечаются "<image>" в приглашении. Ovis-U1 дополнительно генерирует изображения в качестве выходных данных (из задач генерации или редактирования) [39][40][44][43]. Исходный код доступен на GitHub (AIDC-AI/Ovis, Apache 2.0). На лицевой стороне размещены модели весов и карточек: Ovis 1.5 (Llama3-8B, Gemma2-9B), Ovis 1.6 (3B, 9B, 27B), Ovis 2 (1B–34B), Ovis 2.5 (2B, 9B). Приведены примеры логического вывода (Transformers/vLLM), веб-демонстрации (Spaces) и квантизированные версии (включая GPTQ-Int4 для Ovis 1.6 и квантизированные сборки для Ovis 2.0). [39][40][41][44]. Производительность: Ovis 2.5-9B набирает средний балл ~78,3 в мультимодальной таблице лидеров OpenCompass, устанавливая новый рейтинг SOTA среди открытых MLLM по параметрам 40B; Ovis 2.5-2B набирает ~73,9 (SOTA в своем классе). Модель демонстрирует лидирующие показатели в тестах STEM, надежное обоснование и понимание видео, а также самые современные результаты комплексного анализа диаграмм для своего масштаба **[42]**. Ovis 1.6-Gemma2-9B (~10B) входит в число лучших открытых MLLMS с рейтингом менее 30B на OpenCompass, с заявленными оценками в MMBench, MMMU, AI2D и OCRBench (например, MMBench-EN-V1.1 - 78,0, AI2D-84,7) [40]. Подробные результаты тестирования для Ovis 2 (1B–2B) опубликованы в MMBench, MMMU, AI2D, OCRBench, VideoMME и других **[41]**. Для вывода требуются PyTorch 2.4+, Transformers 4.51+ и Flash-Attention 2.7; поддержка vLLM обеспечивает развертывание REST API, совместимого с OpenAI. Использование памяти зависит от разрешения (контролируемого с помощью `min_pixels`/`max_pixels`, например, ~1,0–3,2 МП в примерах) и длины контекста. Для некоторых моделей доступны 8-разрядные и 4-

разрядные квантизированные версии, что снижает требования к видеопамяти [39][44]. Практически: модели 1–2B удобно работают на 8-12 ГБ видеопамяти; модели 9B требуют ~24 ГБ в bf16, при этом требования к 8-битному квантованию ниже (по оценкам, ~2 ГБ видеопамяти на параметры 1B для 16-битного вывода) [44][45]. Базовые модели поддерживают английский и китайский языки. Ovis 2 расширяет возможности многоязычного распознавания текста и выполнения инструкций, охватывая документы, таблицы и диаграммы на разных языках [41][42].

Gemma-3

Gemma-3 — это семейство облегченных моделей открытого типа от Google DeepMind (2025), созданных на основе исследований и технологий Gemini 2.0. Модельный ряд включает в себя варианты с параметрами 270M, 1B, 4B, 12B и 27B, причем модели 4B, 12B и 27B являются мультимодальными (текст + изображения), а модели 270M и 1B - только текстовыми. Длина контекста достигает 128 тыс. токенов (32 тыс. для 1B). Ключевые особенности включают улучшенную архитектуру attention с чередующимися локальными и глобальными уровнями (соотношение 5:1) для снижения нагрузки на KV-кэш в сценариях с длительным контекстом, новый стек vision на основе SigLIP с функцией панорамирования и сканирования для изображений без квадратов и с высоким разрешением, а также официальную поддержку квантования (Int4, SFP8, QAT). Модели разработаны для обеспечения высокой эффективности работы на отдельных ускорителях и поддерживают более 140 языков (более 35 готовых). Экосистема включает в себя ShieldGemma 2 (4B), классификатор безопасности изображений [46][47][48][49]. Обучение включает в себя использование более крупной модели преподавателя в многоязычном смешанном корпусе с изображениями: ~14T токенов (27B), 12T (12B), 4T (4B) и 2T (1B). Токенизатор разработан в соответствии с Gemini 2.0 (SentencePiece, словарный запас 262 тыс.). Архитектурные улучшения включают GQA, QK-норму, скользящее окно с глобальными слоями и веревку с основанием 1 м для расширенного контекста. Компонент vision использует вариант SigLIP (~400 миллионов параметров), совместно используемый и замороженный на 4B/12B/27B; визуальные вложения сведены к 256 векторам. Для высоких или неквадратичных изображений во время вывода применяется функция панорамирования и сканирования. Последующий тренинг включает в себя расширенные этапы дистилляции и RL (например, ЗАКРЕПЛЕНИЕ, РАЗОГРЕВ, деформация) с комбинированными наградами (математика,

код, многоязычие, готовность помочь, безопасность) и фильтрацией данных. Квантованные контрольные точки создаются с помощью QAT (~5 тыс. шагов) **[46]**. Выходные данные включают в себя ответы в виде свободного текста (Markdown/обычный текст), надежную структурированную генерацию (JSON) и вызов функций (через схему JSON) для рабочих процессов, подобных агентам. Модель поддерживает длинный контекст и мультимодальный ввод (изображения; короткое видео, как было объявлено). В шаблонах чата используются управляющие токены "<start_of_turn>...<end_of_turn>`. Структурированные выходные данные и вызов функций поддерживаются в SDK (Vertex AI, GenAI API) и открытых платформах (Transformers, vLLM и т.д.) [46][47]**[50]**. Модели весов и карты доступны на Hugging Face и Kaggle (в соответствии с условиями использования Gemma). Интеграция включает Google AI Studio, Vertex AI и экосистемные инструменты, такие как Ollama, JAX, Keras, Transformers, ROCm и NVIDIA NIM. В середине 2025 года семейство расширилось за счет Gemma 3n (мобильный/аудиовход) и компактной модели Gemma 3 270M [47][48][51][52][53][54]. Производительность: Согласно техническому отчету, Gemma-3-27B-IT конкурирует с Gemini-1.5-Pro по ключевым показателям; Gemma-3-4B-IT превосходит Gemma-2-27B-IT. Эти модели занимают лидирующие позиции в категории “одиночный ускоритель” в рейтинге предпочтений пользователей (LMSYS Arena), значительно улучшая понимание мультимодальных данных (текст + изображения/короткое видео) [46][47][53]. Требования к ресурсам: Приблизительный объем памяти для весов (без учета KV-кэша): 4B ~6,4 ГБ (BF16), 12B ~20 ГБ, 27B ~46,4 ГБ; меньше для SFP8/Int8 (например, 27B ~29,1 ГБ) и ~21 ГБ для 4-разрядного Q4_0. Длинный контекст увеличивает объем кэш-памяти (например, 27 КБ при 32 КБ контекста: ~72,7 ГБ в BF16, ~32,8 ГБ в Int4). Доступны официальные версии с квантованием QAT (для каждого канала Int4, для каждого блока Int4, SFP8) [46][48]. Языковая поддержка: Готовая поддержка более 35 языков и возможность предварительного обучения более чем на 140 языках, что обеспечивается улучшенным набором многоязычных данных и токенизатором [47][46].

Llama-3.1-Nemotron-Nano-VL

Llama-3.1-Nemotron-Nano-VL — это компактная мультимодальная модель vision-language (VLM) от NVIDIA (8B-V1, июнь 2025 г.), разработанная для анализа документов (OCR, DocVQA, ChartQA) и развертывания в центрах обработки данных на периферийных

устройствах. Архитектура сочетает в себе декодер языка команд Llama-3.1-8B и кодер C-RADIOv2-H vision, поддерживающий ввод/вывод до 16 тыс. токенов. Разбиение изображений на плитки поддерживается до 12 фрагментов размером 512×512 с различными соотношениями сторон. Данная модель, получившая лицензию NVIDIA Open Model License со ссылкой на лицензию Llama 3.1 Community Model License, поддерживает ввод изображений и текста и генерирует текстовые выходные данные. Язык ввода: английский. Доступна 4-разрядная версия с квантованием AWQ для периферийного развертывания (через TinyChat/TensorRT-LLM) с заявленной поддержкой Jetson Orin и ноутбуков [55][56][57][58][59]. Обучение проводилось исключительно на основе собственных графических данных на всех трех этапах с использованием внутренних наборов данных NVIDIA NV-Pretraining и NV-CosmosNemotron-SFT, а также набора внутренних, общедоступных и синтетических данных (в том числе для структуры таблиц, обеспечения безопасности и контента, относящегося к предметной области). Ключевые выводы: (i) пары "изображение-текст" недостаточны — необходимы чередующиеся последовательности; (ii) размораживание LLM во время предварительной подготовки с чередованием улучшает обучение в контексте; (iii) повторное смешивание текстовых инструкций имеет решающее значение для поддержания производительности как в задачах VLM, так и только в текстовых задачах. Аннотация является гибридной (человеческая + синтетическая) [55][57]. Выходные данные генерируются в виде произвольного текста со стабильной производительностью в объяснениях, ответах на вопросы и извлечении фактов. Для задач обоснования модель может предсказывать нормализованные координаты ограничивающего прямоугольника в текстовом ответе. Текущая версия поддерживает ввод одного изображения [55][59]. Вес модели и видеокарта доступны на Hugging Face (nvidia/Llama-3.1-Nemotron-Nano-VL-8B-V1); модель видеокарты и варианты развертывания доступны через Build.NVIDIA.com ; Контейнер NIM размещен на NVIDIA NGC (поддерживает NVIDIA AI Enterprise, подписанные изображения); поддерживается интеграция с NeMo 2.0 (преобразование контрольных точек из HF) и TensorRT-LLM. [55][56][57][60]. Производительность: Заявлено, что OCRBench v2 занимает 1-е место по точности; заявленные оценки: MMMU (val) 48,2 %, AI2D 85,0 %, ChartQA 86,3 %, InfoVQA (val) 77,4 %, DocVQA (val) 91,2 %, OCRBench 839, OCRBench v2 EN 60,1 %, CN 37,9 %, VideoMME* 54,7 (*с 1 плиткой/изображением). Модель демонстрирует высокую

производительность при распознавании текста, извлечении таблиц и диаграмм, а также визуальном анализе документов [56][55][58][59]. Среда выполнения: TensorRT-LLM; эталонные тесты выполняются на 1× NVIDIA H100 SXM емкостью 80 ГБ. 4-разрядное квантование AWQ (TinyChat) обеспечивает расширенное развертывание на Jetson Orin и ноутбуках. Размер контейнера NIM составляет ~10,13 ГБ. Визуальный ввод ограничен 12 фрагментами размером 512×512; более высокое разрешение или контекст увеличивают нагрузку на память (KV-кэш) [55][57][58]. Языковая поддержка: английский (согласно карточке модели) **[55]**.

MiMo-VL

MiMo-VL — это семейство открытых мультимодальных моделей от Xiaomi LLM-Core (2025), разработанное для эффективного мультимодального мышления, понимания документов и диаграмм, видео и графического интерфейса пользователя. Базовая линейка включает в себя MiMo-VL-7B-SFT (после многоступенчатого предварительного обучения) и MiMo-VL-7B-RL (с дополнительным смешанным обучением на основе политики). Архитектура состоит из кодера Qwen2.5-ViT vision (с собственным разрешением), проектора MLP и языковой модели на базе MiMo-7B. Он поддерживает длинный контекст (до 32 тыс. токенов на заключительном этапе) и способы преобразования изображений / видео в текст [61][62]**[63]**. Обучение проходит в четыре этапа (общее количество токенов ~2,4 тыс.): (1) прогрев проектора (~300 тыс., L=8 тыс.); (2) настройка зрения и языка (~167 тыс., L=8 тыс.); (3) мультимодальная предварительная подготовка (~1,4 тыс., L=8 тыс.; данные включают подписи к изображениям, чередующийся контент, распознавание текста / обоснование, видео, графический интерфейс пользователя и синтетические рассуждения CoT); (4) SFT с длинным контекстом (~550B, L=32K). За этим следует смешанный RL на основе политики (MORL) с проверяемыми вознаграждениями за выполнение подзадач: визуальное и текстовое обоснование, заземление (включая координаты), визуальный подсчет и временное видео-заземление, дополненное настройкой RHF и предпочтений человека [61][62][63]. Выходные данные генерируются в виде произвольного текста (Markdown/JSON при запросе) с поддержкой потоковой передачи. Управляемый "режим мышления" позволяет подавлять внутренние рассуждения, добавляя команду `/no_think` в конце пользовательского сообщения. Ввод данных осуществляется в формате чата Hugging Face (`{"type": "image"|"video"|"text"}`), при этом мультимедиа помещается перед текстом.

Для задач агента с графическим интерфейсом поддерживаются действия в формате JSON (например, `click`, `scroll`, `input`, `drag`, `open`, `press`, `finished` с координатами/параметрами) [61][63][64]. Модели весов для MiMo-VL-7B-SFT и MiMo-VL-7B-RL, включая обновленную серию 2508, доступны на Hugging Face по лицензии MIT. Исходный код, технический отчет (PDF) и оценочная платформа размещены на GitHub (Apache 2.0). Коллекции моделей также отображаются в ModelScope [62][63][65][61]. Производительность: Согласно техническому отчету, MiMo-VL-7B-RL достигает MMMU (val) 66,7 и OlympiadBench 59,4, превосходя модели в масштабе до 72B; OSWorld-G получил оценку 54,7, что является лучшим показателем точности в тестах с графическим интерфейсом и высоким рейтингом Elo среди открытых виртуальных машин. В обновлении 2508 сообщается о дальнейших улучшениях: MMMU 70.6 и VideoMME 70.8, а также улучшенном управлении режимом мышления и более высоких рейтингах арен [61][63][64]. Модель имеет параметры ~8.31B (BF16). Логический вывод в FP16/BF16 возможен на графических процессорах с ~16-24 ГБ видеопамяти; длинный контекст (до 32 КБ) и видеовход значительно увеличивают использование кэш-памяти KV. 8-разрядное квантование снижает требования к развертыванию. Модель совместима с `Qwen2_5_VLForConditionalGeneration` в Transformers, TGI и vLLM [62][63]. *(Оценки VRAM являются приблизительными.)* Поддержка языков: китайский и английский. Обучение и оценка проводятся на двух языках; во внутренней системе оценки Elo используются сбалансированные китайско-английские запросы [61][63].

dots.ocr

dots.ocr — это открытая многоязычная система анализа документов, разработанная rednote HiLab (июль 2025 г.), объединяющая обнаружение макета и распознавание содержимого в рамках единой модели vision-language (VLM) на основе компактного LLM с ~ 1,7 млрд параметров. Модель поддерживает точное восстановление порядка чтения и обеспечивает результаты SOTA для текста, таблиц и порядка чтения в OmniDocBench. Качество распознавания формул сопоставимо с более крупными системами, такими как Doubao-1.5 и Gemini 2.5 Pro [66][2f]. Переключение задач осуществляется с помощью подсказок — никаких внешних конвейеров или детекторов не требуется [66][2f]. В общедоступной документации подчеркивается архитектурный принцип “одной унифицированной VLM вместо каскада” и оперативное управление задачами; конкретные

этапы обучения и наборы данных не раскрываются. Основное внимание уделяется универсальности (компоновка + распознавание текста в одной модели) и надежности для языков с низким потреблением ресурсов. Оценка проводится с помощью OmniDocBench и внутреннего многоязычного бенчмарка dots.ocr-bench, охватывающего 100 языков [66][2f]. Выходные данные представляют собой единый структурированный объект JSON, содержащий элементы макета, каждый блок которых помечен `bbox=[x1,y1,x2,y2]`, категорией и текстом. Правила форматирования по категориям: *Формула* -- LaTeX; *Таблица* -- HTML; другие блоки -- Markdown; *Изображение* в записях не указывается текстовое поле. Все элементы отсортированы в естественном порядке чтения. Система включает в себя утилиты для создания окончательных файлов ".md" и визуализаций с ограничивающими рамками [66][2f][68]. Карта модели и веса доступны на Hugging Face (лицензия Массачусетского технологического института, тип конвейера "изображение-текст-в-текст"); исходный код размещен на GitHub. Предоставляется онлайн-демонстрация. Официальный образ Docker, основанный на vLLM, обеспечивает простое развертывание [66][2f][69][68]. В эталонном развертывании используются vLLM 0.9.1, PyTorch 2.7.0 (CUDA 12.8) и Flash-Attention 2. Официальный образ Docker занимает ~10,85 ГБ и включает в себя сервер API, совместимый с OpenAI. Модель работает на одном графическом процессоре; для обычных графических процессоров доступны 4-разрядные квантизированные версии (NF4), что снижает требования к видеопамяти. Длинные выходные данные и большие PDF-файлы увеличивают нагрузку на KV-кэш; пропускная способность еще не оптимизирована для очень длинных последовательностей [66][2f][69][70]. Языковая поддержка: Многоязычная модель, проверенная на 100 языках (dots.ocr-bench). Официальные теги: `Английский`, `Китайский`, `многоязычный`. В качестве примеров можно привести тибетский, традиционный китайский, голландский, каннада и русский **[66]**.

h2ovl-mississippi-800m

H2OVL-Mississippi-800M — это компактная (≈0,8B) модель визуального языка (VLM) от компании H2O.ai, специализирующейся на распознавании текста и понимании документов. Построенный на архитектуре ViT-MLP-LLM, он сочетает в себе визуальный кодер InternViT-300M, проектор MLP и языковой декодер серии H2O-Danube (Danube-3, ≈0,5B), интегрированный в стек авторегрессионных декодеров. В модели используется

динамическая обработка с высоким разрешением: изображения разбиваются на блоки размером 448×448 пикселей (обычно 1-6 фрагментов) с понижающей дискретизацией в случайном порядке, что сокращает количество визуальных символов до 256 на фрагмент. Это обеспечивает точное распознавание мелкого текста и устойчивость к нестандартным форматам изображения. Модель, выпущенная под лицензией Apache 2.0, в основном ориентирована на распознавание текста и извлечение структурированной информации из документов, таблиц и диаграмм [71][72]. В процессе обучения для варианта 0.8B было использовано около 19 миллионов пар "изображение-текст": двухэтапное предварительное обучение (≈11,45 млн пар - сначала только для проектора, затем проектор+LLM с замороженным ViT), за которым последовала тонкая настройка (≈7,89 млн пар), ориентированная на распознавание текста, DocQA, таблицы, и диаграммы. На заключительном этапе все компоненты (ViT, MLP, LLM) проходят совместное обучение. Общий объем вычислений для серии Mississippi составил ~240 часов на графических процессорах 8×H100 [72].
Выходные данные генерируются в виде текста с поддержкой структурированных форматов (JSON) при появлении запроса. Приведены инструкции по извлечению форм, таблиц и диаграмм в формате JSON. Ввод данных осуществляется по шаблону чата с заполнителем "<image>" [71]. Весы и карта моделей доступны на Hugging Face (h2oai/h2ovl-mississippi-800m, Apache 2.0), с примерами вывода с использованием PyTorch/Transformers и Flash-Attention 2. Официальные объявления, документация и примечания к выпуску серии Mississippi (0.8B и 2B) опубликованы на H2O.ai это блог и веб-сайт [71][73][74][75]. Производительность: достигает SoTA в OCRBench: Распознавание текста с оценкой *274* для Mississippi-0,8балла, значительно превосходя более крупные модели. Результаты тестирования для модели 0.8B в 8 наборах данных: MMBench 47.7, MMMU (val) 39.1, MathVista 34.0, AI2D (тест) 29.6, MMVet 30.0, OCRBench (всего) 751. Модель демонстрирует высокую производительность в DocVQA, TextVQA и InfoVQA относительно своего размера [72][71]. Размер модели: ~826 м, параметры (BF16). Рекомендуемая настройка логического вывода: PyTorch 2.x + Transformers (с `trust_remote_code`) и Flash-Attention 2. Обычно работает на одном пользовательском графическом процессоре (8-12 ГБ видеопамяти для FP16/BF16). Вывод данных возможен

только с помощью центрального процессора (проверено сообществом), хотя и значительно медленнее. Длина выходных данных влияет на использование кэш-памяти KV [71][76].

MiniCPM-o-2_6

MiniCPM-o-2_6 — это "универсальная" MLLM из серии MiniCPM от OpenBMB (январь–март 2025 г.), объединяющая визуализацию, речь и текст в единый сквозной стек. Модель объединяет в себе визуальный кодер SigLIP-400M, аудиокодер Whisper-medium-300M, аудиодекодер ChatTTS-200M и языковую модель Qwen-2.5-7B с общим объемом параметров ~8B. Он поддерживает непрерывные видео- и аудиопотоки, голосовое взаимодействие в режиме реального времени и прямую трансляцию на периферийных устройствах, включая планшеты, такие как iPad. Для изображений он обрабатывает произвольные соотношения сторон и разрешения до ~1,8 МП (например, 1344×1344) с высокой плотностью маркеров (~640 визуальных маркеров при 1,8 МП) [77][78]. Обучение включает в себя комплексную совместную оптимизацию всех модальностей (SigLIP, Whisper, ChatTTS) с LLM с использованием CE loss. Внедрен механизм мультиплексирования с временным разделением (TDM), позволяющий чередовать параллельные мультимодальные потоки с мелкими временными интервалами в магистрали LLM, обеспечивая обработку в режиме реального времени. "Подсказка аудиосистемы" позволяет настроить голос (тембр, эмоции, скорость) при выводе. Методы из семейства RLAIF-V/VisCPM применяются для повышения надежности и уменьшения галлюцинаций [77][78]. Выходные данные включают текст (Markdown /JSON при появлении запроса) и речь (TTS с контролем тембра, эмоций и скорости), включая сквозное клонирование голоса. Возможности ввода: изображения (в том числе с несколькими изображениями), видео (непрерывный поток), аудио (ASR/STT) и текст. Поддерживает потоковую передачу как речи, так и зрения [77][78]. Весы и карта модели доступны на лицевой стороне (openbmb/MiniCPM-o-2_6), включая варианты int4 и GGUF для llama.cpp. Код, документация, веб-демонстрации и руководства по интеграции (vLLM, Ollama, llama.cpp) размещены на GitHub (OpenBMB/MiniCPM-o). Лицензирование: код под Apache 2.0; веса под лицензией MiniCPM Model (бесплатно для академического использования; бесплатно для коммерческого использования после регистрации) [77][79][80]. Производительность: на плате model card средняя оценка OpenCompass составляет 70,2. Превосходит GPT-4o-

202405, Gemini 1.5 Pro и Claude 3.5 Sonnet в задачах с одним изображением и превосходит GPT-4V и Claude 3.5 Sonnet в задачах с несколькими изображениями и пониманием видео. Тесты для нескольких изображений/видео: BLINK (val) = 56,7, Mantis Eval = 71,9, MIRB = 58,6, Video-MME = 63,9 (без субтитров) / 67,9 (с субтитрами). В задачах, связанных с речью /аудиозаписью, обеспечивает конкурентные показатели ASR / AST и разговорной речи, при этом сообщается о превосходстве над GPT-4o-realtime в открытых оценках звука. Поддерживает ролевые игры, управление голосовым стилем и персонализированные голосовые профили. В StreamingBench превосходит GPT-4o-202408 и Claude 3.5 Sonnet в сценариях всенаправленного понимания в реальном времени [77][78]. Эффективное время выполнения благодаря высокой плотности токенов: 1,8 мегапикселя -- ~640 визуальных токенов. Поддерживает vLLM (высокая пропускная способность), Ollama, llama.cpp (режим только для просмотра) и квантизированные версии (int4 ~7 ГБ видеопамяти; GGUF для CPU/GPU). Для вывода FP16 в моделях класса 8B обычно требуется графический процессор с 16-24 ГБ видеопамяти; потоковое видео/аудио увеличивает нагрузку на KV-кэш [77][79][80]. Языковая поддержка: более 30 языков в текстовом режиме; двуязычная голосовая поддержка (английский / китайский) с настраиваемыми и клонируемыми голосами [77].

MiniCPM-V-4

MiniCPM-V-4 — это эффективная мультимодальная модель из серии MiniCPM от OpenBMB (март 2025 г.), разработанная для периферийного развертывания (мобильные устройства, ПК) с сохранением мощных возможностей для работы с документами и визуального восприятия. Архитектура сочетает в себе SigLIP2-400M (vision encoder) и MiniCPM4-3B (LLM) с помощью мультимодального адаптера, что в сумме дает ~4,1 миллиарда параметров. В качестве входных данных поддерживается одно/ несколько изображений и видео; на выходе - текст. Достигает 69,0 баллов в тесте OpenCompass aggregate benchmark (8 заданий), превосходя GPT-4.1-mini-20250414, MiniCPM-V-2.6 (8.1B) и Qwen2.5-VL-3B-Instruct [81]. Основой языка является MiniCPM4-3B, использующий инновации MiniCPM4 в области повышения эффективности: InfLLM-v2, UltraClean/UltraChat v2 и оптимизированное обучение/логический вывод. Мультимодальный посттренинг проводится по рецептам серии MiniCPM-V, включая VisCPM, LLaVA-UHD и RLHF-V/RLAIF-V для повышения надежности и уменьшения

галлюцинаций. В карточке модели указано использование коллекции RLAIF-V для точной настройки предпочтений [81][82]**[83]**. Выходные данные состоят из текстовых ответов (Markdown/JSON при запросе) в стандартном формате чата Transformers. Поддерживает многооборотный диалог, чередование изображения и текста и видеовход. API-интерфейсы доступны через vLLM, SGLang, llama.cpp и Ollama; предоставляется собственная демонстрация iOS [81]. Веса моделей и карта доступны на Hugging Face (openbmb/MiniCPM-V-4); код, руководства и демонстрации размещены на GitHub (OpenBMB/MiniCPM-V). В комплект входят готовые двоичные файлы для Олламы и llama.cpp, а также кулинарная книга по использованию. Лицензирование: код под управлением Apache 2.0; веса моделей под лицензией MiniCPM Model (бесплатно для академического использования; коммерческое использование регулируется условиями лицензии) [81][84][85]. Производительность: OpenCompass (8 тестов, одно изображение): 69,0 (MiniCPM-V-4, 4.1B) против 68,9 (GPT-4.1-mini), 65,2 (MiniCPM-V-2.6), 64,5 (Qwen2.5-VL-3B-Instruct). Дополнительные оценки: OCRBench 894, MathVista 66,9, HallusionBench 50,8, MMMU 51,2, MMVet 68,0, MMBench 79,7, MMStar 62,8, AI2D 82,9. В задачах, связанных с несколькими изображениями и видео, он достигает конкурентных результатов: Mantis 71,4, Blink 54,0, Video-MME 61,2 (без субтитров) / 65,8 (с) [81]. Разработан для повышения эффективности работы на устройстве: время получения первого токена составляет <2 секунд, а на iPhone 16 Pro Max -> 17 токенов в секунду, что обеспечивает высокую пропускную способность при одновременной загрузке. Поддерживает локальное развертывание с помощью PyTorch + Transformers (`trust_remote_code`), vLLM, SGLang, llama.cpp и Ollama. Модель 4.1B удобно работает на обычных графических процессорах с ~8-12 ГБ видеопамяти (приблизительная оценка; зависит от длины контекста и видеовхода) [81][85]. Языковая поддержка: двуязычная (английский/китайский). Серия MiniCPM-V позиционируется как первое многофункциональное устройство с возможностью развертывания на месте и мультимодальным взаимодействием на двух языках. Более ранние версии серии демонстрировали поддержку более 30 языков (в зависимости от контекста серии) [84][82].

olmOCR

olmOCR — это открытая комплексная система распознавания текста, разработанная Институтом искусственного интеллекта Аллена, основанная на точно настроенной мультимодальной модели Qwen-VL-7B-Instruct. Он одновременно "видит" всю страницу документа и генерирует линейный текстовый вывод в правильном порядке чтения. Входные данные представляют собой изображение страницы (при необходимости дополненное метаданными PDF); выходные данные представляют собой структурированный текст с сохранением логической структуры, включая таблицы (построчно) и математические формулы в LaTeX [27][86][87]. Модель была полностью доработана и адаптирована с помощью LoRa для набора данных olmOCR-mix-0225, состоящего из ~260 000 страниц из ~100 000 PDF-файлов, включая научные статьи, брошюры и рукописные сканы. Обучение проводилось на 8-кратных графических процессорах NVIDIA H100, что позволило достичь сходимости примерно за 10 000 шагов. Для повышения точности чтения были проведены эксперименты с введением координат блоков и других метаданных в формате PDF [86][87]. Выходные данные формируются в формате Markdown с сохранением заголовков, абзацев, списков, таблиц и формул (как в LaTeX). Также доступен режим простого текста, исключающий форматирование. Оба режима обеспечивают правильную линеаризацию, не полагаясь на внешние средства анализа макета [27][87]. Исходный код, веса моделей, обучающие сценарии и набор данных находятся в открытом доступе по открытой лицензии в репозитории GitHub allenai/olmocr. Предоставляется публичная демонстрация и подробная документация [27][86]. Производительность: Соответствие на уровне слов с GPT-4o (используемым в качестве эталонного) достигает 0,875. В ходе парных экспертных оценок 75 сложных документов olmOCR превзошел Tesseract и PaddleOCR примерно в 70 % случаев. Скорость обработки составляет ~1 страницу в секунду на A100-80 ГБ (оптимизированная); базовая скорость без оптимизаций составляет ~0,4 страницы в секунду. Оптимизированный вариант RolmOCR быстрее, но немного ниже по качеству [27][87]. Скорость вывода: olmOCR-7B обрабатывает ~1500 токенов в секунду на A100-80 ГБ и ~3000 токенов в секунду на H100-80 ГБ. Ориентировочная стоимость обработки 1 миллиона страниц составляет ~190 долларов США при крупномасштабных пакетных запусках [87]. Языковая поддержка: обучен в основном работе с английскими PDF-файлами; хорошо работает с другими языками, использующими латиницу с похожими

алфавитами. Поддержка нелатинских шрифтов ограничена и требует дополнительной доработки [27][87].

RolmOCR

RolmOCR ("Усовершенствованный olmOCR") — это облегченная версия olmOCR, разработанная компанией Reducto AI в апреле 2025 года. Эта модель представляет собой усовершенствованный Qwen 2.5-VL-7B и работает исключительно с изображениями страниц, не полагаясь на метаданные PDF. Ее мощный кодировщик vision самостоятельно восстанавливает логический порядок чтения. Примерно 15 % обучающих выборок были случайным образом изменены, что повысило устойчивость к искаженным и перевернутым документам [26]. При обучении использовался тот же набор данных AllenAI olmOCR, но был осуществлен переход на Qwen 2.5-VL с дополнениями на основе ротации. Архитектура по-прежнему основана на кодере vision Transformer в паре с декодером LLM, который генерирует связный последовательный текст. Тонкая настройка была оптимизирована для устранения зависимости от внешних подсказок и уменьшения длины последовательности входных токенов [26]. Выходные данные представляют собой линеаризованный, упорядоченный текстовый поток в обычном формате TXT или JSON. Во время пакетной обработки результаты с нескольких страниц объединяются в единую непрерывную последовательность [26]. Исходный код и веса ("reducto/RolmOCR-7B") доступны под лицензией Apache-2.0 на Hugging Face [88]. Модель совместима с vLLM и поддерживает конечные точки API, совместимые с OpenAI [26]. Производительность: при обычном сканировании достигается ~5 % CER, при этом WER в пределах нескольких процентных пунктов (незначительные опечатки). По сравнению с olmOCR вывод данных выполняется на 20-30 % быстрее, а использование видеопамяти сокращается на ~30 %. Качество не уступает коммерческим системам распознавания текста, в том числе для многостраничных документов [26]. Требования к ресурсам: модель с 7B параметрами лучше всего развертывать с помощью vLLM; логический вывод эффективно выполняется на одном графическом процессоре с ~24 ГБ видеопамяти, что сокращает затраты на память и задержку по сравнению с ее предшественницей при практическом развертывании [26]. Языковая поддержка: программа работает в основном с данными на английском языке, но благодаря Qwen 2.5-VL она точно извлекает текст на смешанном французском, китайском

и других языках. Выделяет курсивом, рукописными аннотациями и на полях с минимальным ухудшением качества [26].

Промежуточный вывод

Возможности современного искусственного интеллекта для обработки документов и распознавания текста значительно изменились в сторону унифицированных, сквозных мультимодальных моделей, способных выполнять множество задач, таких как обнаружение текста, распознавание, анализ макета, разбор таблиц и генерация структурированных выходных данных, в рамках единой платформы. Эта эволюция обусловлена появлением больших моделей на языке визуализации (VLM) и интегрированных систем, которые выходят за рамки традиционных модульных конвейеров распознавания текста.

Donut (Document Understanding Transformer) - это инновационная комплексная модель, которая устраняет необходимость в отдельных этапах обнаружения и распознавания. Она использует преобразователь Swin и декодер на базе BART для прямого преобразования изображений документов в структурированные выходные данные, такие как JSON или Markdown. Предварительно обученный работе с большим набором синтетических данных (SynthDoG), охватывающим около 38 языков, Donut обеспечивает высокую производительность при классификации документов, анализе форм и визуальном ответе на вопросы. Он эффективен, обрабатывает страницы примерно за 80 миллисекунд на графическом процессоре T4 и доступен по лицензии MIT.

DiT (Document Image Transformer) ориентирован на понимание макета и визуальной структуры. В нем используется кодировщик vision transformer, предварительно обработавший более 11 миллионов сканированных документов без маркировки из IIT-CDIP, что позволяет надежно распознавать текстовые блоки, таблицы и рисунки, не полагаясь на текстовое содержимое. Хотя DiT сам по себе не выполняет распознавание текста, он служит мощной основой для последующих моделей. В сочетании с Cascade R-CNN он обеспечивает высокую оценку карт в PubLayNet. Его дизайн, не зависящий от языка, делает его пригодным для анализа многоязычных документов.

GOT-OCR2.0 представляет собой следующее поколение систем распознавания текста, сочетающих локализацию и распознавание текста в единой архитектуре кодера-декодера. Имея около 580 миллионов параметров, он поддерживает ввод полностраничных

и обрезанных изображений и может генерировать выходные данные в различных форматах, включая обычный текст, Markdown, LaTeX и TikZ. Он отлично распознает сложный контент, такой как математические формулы, химические структуры и нотную запись. Обученный работе как с реальными, так и с синтетическими данными, GOT-OCR2.0 достигает самых современных результатов в таких тестах, как FOX, превосходя даже GPT-4V в некоторых задачах. Для логического вывода требуется около 16 ГБ памяти графического процессора, а для потребительского оборудования поддерживается 8-битное квантование.

PaddleOCR, разработанная Baidu, остается одной из наиболее полных платформ распознавания текста с открытым исходным кодом. Он объединяет облегченные модели для обнаружения текста (DB, RT-DETR), распознавания (CRNN, SVTR) и постобработки, а также расширенные модули для разбора макета и извлечения таблиц. Его конвейер TableMASTER очень эффективен для анализа научных документов, обеспечивая высокие оценки в TEDS на PubTabNet. Последние версии, такие как PP-ChatOCRv4-doc, поддерживают сквозное преобразование PDF-файлов в Markdown или JSON, включая порядок чтения, таблицы и штампы. PaddleOCR поддерживает более 80 языков и предлагает оптимизированные модели для периферийного развертывания через ONNX и OpenVINO.

Серия Qwen от Alibaba превратилась в ведущее семейство мультимодальных моделей. Qwen-VL и его преемники, особенно Qwen2.5-VL, демонстрируют исключительные возможности распознавания текста и понимания документов. С размерами параметров от 3 до 72 Б, эти модели справляются с различными задачами, включая распознавание текста, разбор таблиц и интерпретацию диаграмм. Они генерируют структурированные выходные данные в HTML, JSON или Markdown и поддерживают пространственную локализацию с помощью тегов, ограничивающих рамки. Qwen2.5-VL-72B обеспечивает производительность, сравнимую с GPT-4V в DocVQA и ChartQA, при этом коэффициент полезного действия составляет около 4-5 % при работе со сложными многоязычными документами. Модели созданы с открытым исходным кодом под управлением Apache 2.0 и поддерживают различные уровни квантования для гибкого развертывания.

InternVL3, разработанный OpenGVLab и Shanghai AI Lab, представляет архитектуру ViT-MLP–LLM с унифицированным мультимодальным предварительным обучением. Он поддерживает визуальное кодирование местоположения с переменной скоростью и передовые методы обучения, такие как MPO и VisualPRM. Семейство включает модели с параметрами от 1B до 78B, при этом InternVL3-78B устанавливает новые рекорды среди открытых MLLM на MMMU. Он поддерживает ввод нескольких изображений и видео, что делает его подходящим для сложных вычислений и задач, подобных агентам. Модели доступны в Hugging Face и ModelScope под управлением Apache 2.0 и обеспечивают высокую производительность в понимании документов, анализе диаграмм и пространственном мышлении.

Ovis, еще один проект Alibaba AIDC-AI, подчеркивает структурное соответствие между визуальными и текстовыми маркерами. Ovis2 и Ovis2.5 вводят "режим мышления" для рефлексивного мышления и обучаются с использованием цепочки размышлений и обучения с подкреплением с проверяемыми вознаграждениями. Модели поддерживают мультимодальный диалог, генерацию изображений и редактирование. Ovis2.5-9B обеспечивает самые современные результаты в OpenCompass, особенно в понимании STEM и диаграмм. Эта серия полностью основана на открытых источниках и поддерживает развертывание с помощью vLLM и Transformers.

Семейство облегченных моделей Google DeepMind Gemma-3 включает в себя мультимодальные варианты (4B, 12B, 27B), разработанные для повышения эффективности работы на одиночных ускорителях. Построенный на технологии Gemini 2.0, он оснащен улучшенными механизмами внимания, стеком зрения на основе SigLIP и встроенной поддержкой 4-битного и 8-битного квантования. Модели Gemma-3 поддерживают длинные контексты (до 128 тыс. токенов) и обучаются на больших многоязычных наборах данных. Они превосходны в мультимодальном понимании, структурированной генерации и вызове функций, а также обладают высокой производительностью в OCRBench и DocVQA. Доступные по лицензии Gemma, они хорошо интегрируются с Vertex AI, Ollama и Hugging Face.

Llama-3.1-Nemotron-Nano-VL от NVIDIA — это компактная мультимодальная модель 8B, оптимизированная для развертывания на периферии и в центрах обработки данных. Созданный на базе Llama-3.1 и C-RADIOv2-H vision encoder, он поддерживает до

16 тыс. токенов и разбиение на листы для изображений с высоким разрешением. Разработанный на основе внутренних наборов данных NVIDIA, он хорошо справляется с распознаванием текста, извлечением таблиц и контролем качества документов. 4-разрядная квантованная версия AWQ позволяет использовать ее на Jetson Orin и ноутбуках. Она распространяется по лицензии NVIDIA Open Model и поддерживает интеграцию с TensorRT-LLM и NeMo.

MiMo-VL, разработанный Xiaomi, ориентирован на мультимодальное мышление и понимание документов. Основанный на Qwen2.5-ViT и MiMo-7B, он поддерживает длительный контекст (32 тыс. токенов) и углубленное обучение со смешанным обучением с подкреплением политики. MiMo-VL-7B-RL достигает высоких результатов в MMMU и OSWorld, превосходно справляется с задачами, связанными с графическим интерфейсом, и обучением работе с видео. Модель поддерживает управление в режиме thinking mode и доступна по лицензии MIT. Он совместим с vLLM и Transformers и подходит для развертывания на графических процессорах с 16–24 ГБ видеопамяти.

dots.ocr — это компактная многоязычная система анализа документов с примерно 1,7 миллиардами параметров. Она объединяет определение макета и распознавание содержимого в одном VLM, поддерживающем 100 языков. Модель выводит структурированный JSON с ограничивающими рамками, категориями и текстом в соответствующих форматах (LaTeX для формул, HTML для таблиц). Она обеспечивает самые современные результаты в OmniDocBench и поддерживает сквозную генерацию Markdown. Доступный по лицензии MIT, он включает в себя образы Docker и API, совместимые с OpenAI, для упрощения развертывания.

h2ovl-mississippi-800m от H2O.ai — это облегченный VLM (параметры ~800 м), разработанный для эффективного распознавания текста и понимания документов. Он использует InternViT-300M и H2O-Danube-3 с динамической обработкой с высоким разрешением для точного распознавания текста. Обработано около 19 миллионов пар изображение-текст, и, несмотря на свой небольшой размер, он обеспечивает высочайшую производительность в OCRBench. Он работает на обычных графических процессорах с 8–12 ГБ видеопамяти и поддерживает логический вывод только для центрального процессора. Модель работает с открытым исходным кодом под управлением Apache 2.0.

MiniCPM-V-4 и MiniCPM-o-2_6 от OpenBMB — это эффективные модели, предназначенные для периферийного развертывания. MiniCPM-V-4 (параметры 4,1B) сочетает в себе SigLIP2 и MiniCPM4-3B, обеспечивая высокую производительность в OpenCompass и OCRBench. Он поддерживает ввод нескольких изображений и видео и эффективно работает на мобильных устройствах. MiniCPM-o-2_6 (8B) объединяет визуализацию, речь и текст, обеспечивая мультимодальное взаимодействие в режиме реального времени с голосовым выводом. Обе модели имеют открытый исходный код и поддерживают развертывание через Ollama, vLLM и llama.cpp.

olmOCR и RolmOCR — это модели, ориентированные на работу с документами, производные от Qwen-VL. olmOCR, разработанный Allen Institute for AI, отлично работает с большим набором научных PDF-файлов и генерирует хорошо структурированную разметку с правильным порядком чтения, таблицами и формулами LaTeX. Он обеспечивает высокую точность по сравнению с GPT-4o. RolmOCR, усовершенствованная версия от Reducto AI, повышает скорость и сокращает использование видеопамяти при сохранении качества. Она быстрее и экономичнее использует память, подходит для пакетной обработки многостраничных документов.

Подводя итог, можно сказать, что отрасль движется к созданию унифицированных комплексных моделей, сочетающих высокую точность с глубоким пониманием структуры. В то время как традиционные инструменты распознавания текста, такие как PaddleOCR, остаются надежными и готовыми к работе, крупные VLM, такие как Qwen2.5-VL, InternVL3 и Ovis, обеспечивают превосходную контекстную и макетную осведомленность. Компактные модели, такие как dots.ocr, h2ovl-mississippi и MiniCPM-V-4, предоставляют эффективные альтернативы для периферийного развертывания. Выбор модели зависит от варианта использования: точности, скорости, языковой поддержки и среды развертывания. Инновации с открытым исходным кодом продолжают стимулировать прогресс, делая продвинутый искусственный интеллект для обработки документов доступным для широкого спектра приложений.

1.3 Обнаружение и распознание текста

EasyOCR

EasyOCR реализует двухэтапный конвейер: сначала детектор CRAFT локализует области текста; затем распознаватель CRNN с декодированием CTC обрабатывает каждую обрезанную область. CRNN использует средство извлечения сверточных признаков (ResNet) и двунаправленный LSTM, что позволяет распознавать последовательности символов без ручной сегментации [89][90]. Базовые значения CRAFT и CRNN обрабатываются на основе синтетического текста и текста из реальной сцены. Для новых языков поддерживается тонкая настройка распознавателя с использованием строк аннотированного текста [90]. Библиотека выводит:

- Координаты ограничивающего прямоугольника на уровне слов (или точек многоугольника) в формате $[[x_1,y_1],...]$;
- Распознанный текст и оценка достоверности для каждого прямоугольника;
- При необходимости, полный текст страницы, отсортированный по координате Y для базового порядка чтения [90]. Открытый исходный код доступен под лицензией Apache 2.0 в репозитории JaidedAI/EasyOCR. Предварительно подготовленные веса для более чем 80 языков распространяются с помощью пакета PyPI `easyocr` [90]. Производительность: при сканировании испанских документов формата A4 без точной настройки EasyOCR достигает 19 % и 33 % соответственно, что ниже, чем у модели TrOCR с точной настройкой [91]. В многоязычном тесте Roboflow средняя точность распознавания символов составляет ~71 % (английская подгруппа). В ICDAR2015 CRAFT достигает f ≈86-87 % для распознавания текста при IoU > 0,5 [89]. Процесс вывода занимает ~0,2 секунды на каждую текстовую строку; обработка всей страницы формата A4 занимает 1-2 секунды. На графическом процессоре (V100) скорость достигает ~30 кадров в секунду. Объем модели CRNN составляет ~44 МБ, CRAFT ~17 МБ, что позволяет EasyOCR работать на устройствах с объемом видеопамяти менее 2 ГБ [90]. Языковая поддержка: предварительно подготовленные весы поддерживают более 80 языков, включая латиницу, кириллицу, китайский, арабский, деванагари и другие. Библиотека поддерживает одновременное указание нескольких языков, обеспечивая многоязычное распознавание за один проход [90].

Tesseract

Tesseract 5 (ранее 4+) — это классический OCR-движок с открытым исходным кодом, который сочетает традиционную сегментацию макета с нейронным распознавателем на основе LSTM ("новый OCR-движок") для сквозного распознавания текста на уровне строк без обнаружения на основе CNN. Алгоритм сначала разбивает изображение на блоки, строки и слова, затем рекуррентная сеть предсказывает последовательность символов для каждой текстовой строки [3][92]. Предварительно подготовленные файлы языковых данных (traineddata) предоставляются в комплекте поставки. Движок поддерживает тонкую настройку пользовательских шрифтов и языков с помощью пакета "tesseract-training" - для простых случаев может быть достаточно всего 3-5 изображений с аннотациями. Этот процесс включает в себя создание пар .box/.tif, запуск обучающих сценариев и создание пользовательских файлов *.traineddata [94][92]. Выходные форматы включают: обычный TXT, hOCR (HTML с ограничивающими рамками), PDF с возможностью поиска, PDF с невидимым текстом, TSV, ALTO XML и PAGE XML, доступные с помощью инструмента командной строки "tesseract` [92]. Исходный код размещен на GitHub (tesseract-ocr/тессеракт) под лицензией Apache 2.0. Доступны стабильные сборки для Linux, Windows и macOS, а также C/C++ API для интеграции в приложения [92]. Производительность: в сравнительном исследовании, проведенном ICFOSS (ICON 2024), Tesseract достиг точности 92 % на английском и 93 % на хинди, превзойдя EasyOCR и PaddleOCR в том же тесте. Однако при работе со сложными документами или документами с фотографиями точность снижается из-за ошибок сегментации макета [93]. Работает полностью на процессоре без зависимости от графического процессора. В практическом примере сообщается об обработке ~2 миллионов изображений в месяц на десятках стандартных серверов. Обучение может быть выполнено в контейнере Docker на процессорах x86. Зависимости минимальны — ограничены Leptonica и стандартным компилятором C++ [94][92]. Языковая поддержка: по умолчанию распознает более 100 языков, включая латиницу, кириллицу, китайский, арабский, деванагари, вертикальные шрифты (например, японский) и другие. Поддерживается полное покрытие Unicode, и новые языки могут быть добавлены с помощью пользовательских файлов traineddata [94][92].

TrOCR

TrOCR (Transformer OCR) — это комплексная система распознавания текста, полностью основанная на архитектуре transformer. Он сочетает в себе визуальный кодер ViT/DeiT с текстовым декодером GPT-2/Roberta, позволяя извлекать элементы изображения и генерировать текст с авторегрессией без необходимости явной сегментации символов [95]. Были представлены три варианта модели: Малая (параметры ~62 м), базовая (~334 м) и большая (~558 м). Предварительное обучение проводилось на больших синтетических массивах печатных строк текста и рукописных изображений, за которыми следовала контролируемая тонкая настройка на реальных наборах данных. Для новых языков декодер может быть адаптирован (например, с использованием mBART), и полная модель может быть доработана с минимальными затратами данных [95]. На выходе получается последовательность символов UTF-8, декодируемая с помощью CTC или кодирования парами байт. Распознавание на уровне слова или подслова может быть достигнуто путем настройки конфигурации декодера [95]. Исходный код и предварительно подготовленные веса доступны в репозитории microsoft/OCR-Transformer и интегрированы в Hugging Face Transformers, что упрощает развертывание и тонкую настройку [95]. Производительность: TrOCR-Large превзошел современные методы SOTA в распознавании печатного, рукописного текста и сцен. Он обеспечил значительно более низкие показатели CER и WER для печатных документов на английском языке по сравнению с EasyOCR и PaddleOCR [95] Тест Roboflow 2025 года подтвердил, что TrOCR-Large является лучшей моделью с открытым исходным кодом для задач печати на английском языке и рукописного ввода IAM. Усовершенствованный вариант TrOCR для испанского языка установил новый SOTA для испанского текста с CER ≈6,3 % [91]. Для вывода данных для TrOCR-Large требуется ~12 ГБ видеопамяти (FP16), а графический процессор A100 обрабатывает 50-60 строк в секунду. Варианты меньшего размера (Small/Base) работают быстрее и вмещают 4-8 ГБ видеопамяти [95]. Языковая поддержка: базовые модели обучаются английскому языку с использованием латинского алфавита. Благодаря не зависящему от языка дизайну TrOCR может быть эффективно адаптирован к другим сценариям. Существуют рабочие модели для испанского, немецкого, французского и русского языков с продемонстрированной адаптацией к кириллице и деванагари [95][91].

DocTR (Mindee)

DocTR — это библиотека распознавания текста с открытым исходным кодом, построенная на двухэтапном конвейере: распознавание текста (по умолчанию: DBNet) [16]; распознавание символов (CRNN, SAR и другие) [96]. Поддерживаются альтернативные детекторы, такие как LinkNet и FAST, позволяющие выбирать модель на основе расположения текста и требований к скорости [96]. Разработчики предоставляют предварительно подготовленные веса. В разделе "Обучите свою собственную модель" описан полный цикл обучения для пользовательских наборов данных с использованием TensorFlow 2 или PyTorch. Для точной настройки требуется только заменить алфавит и снабдить пользовательские изображения аннотациями [96]. Выходные данные для каждого слова включают в себя: координаты ограничивающей рамки, распознанный текст и показатель достоверности. Страницы структурированы в виде иерархического объекта Документ -- Страница -- Блок/строка/Слово, что облегчает анализ макета и последующую обработку [96]. Исходный код доступен под лицензией Apache-2.0 в репозитории GitHub mindee/doctr. Библиотека может быть установлена с помощью "pip install python-doctr" или "pip install doctr" и поддерживает логический вывод как на CPU, так и на GPU [96]. Производительность: Внутренние тесты Mindee показывают, что DocTR обладает высокой производительностью. При публичных сравнениях изображений низкого качества DocTR превзошел другие инструменты распознавания текста с открытым исходным кодом, достигнув более 95 % точности распознавания символов и приблизившись к производительности Google Vision и Azure OCR. Детектор DBNet в рамках DocTR достигает ~87-90 % F1 при IoU > 0,5 на ICDAR-2015 [16]. Потребности в ресурсах: Полный конвейер `ocr_predictor(det='db_resnet50', reco='crnn_vgg16_bn')` обрабатывает страницу формата A4 за ~50-70 мс на графическом процессоре RTX 3080. Использование FP16 precision (Amp) сокращает время вывода до ~35 мс при незначительной потере точности. Однако модели CRNN-VGG16 демонстрируют заметное ухудшение качества FP16, а конфигурации на основе ViT в настоящее время не поддерживают чистый FP16 [97]. На процессоре (8-12 ядер) обработка страницы занимает 0,3–0,6 секунды. Использование видеопамяти составляет ~1,8 ГБ для стандартного конвейера при размере пакета 1. Языковая поддержка: Предварительно подготовленные модели оптимизированы для использования латинского алфавита (~95 символов: A-Z, от A

до Я, 0-9, основные знаки препинания). Детектор не зависит от языка; для поддержки кириллицы, арабского алфавита или CJK требуется только переобучение модуля распознавания на целевой набор символов. Инструкции по расширению алфавита и переобучению приведены в документации [96]. Рукописный текст поддерживается только при специальной настройке. Решаемые задачи: обнаружение текста, распознавание текста, анализ макета документа, многоязычное распознавание текста (с тонкой настройкой), распознавание рукописного текста (с тонкой настройкой).

Сравнение моделей OCR

В представленном тексте представлен всесторонний обзор современного состояния распознавания текста и мультимодальных моделей искусственного интеллекта, подчеркивающий четкую тенденцию к созданию унифицированных сквозных архитектур, которые заменяют традиционные многоступенчатые конвейеры. Анализ показывает значительную эволюцию в этой области. Классические модели, такие как Tesseract и EasyOCR, представляют собой устоявшийся модульный подход, основанный на отдельных этапах обнаружения и распознавания. Несмотря на свою эффективность и высокую доступность, их производительность часто ограничена из-за распространения ошибок при первоначальном анализе компоновки. В отличие от этого, модели нового поколения, такие как Donut, GOT, olmOCR и dots.ocr, построены на мощных мультимодальных LLM (например, Qwen, Llama) и предназначены для сквозной обработки данных. понимание документов. Эти модели обрабатывают все изображение документа одновременно, непосредственно генерируя структурированные выходные данные, такие как JSON или Markdown. Такой целостный подход позволяет им преуспевать в решении сложных задач, требующих понимания контекста и пространственных взаимосвязей, таких как поддержание правильного порядка чтения, извлечение данных из таблиц и интерпретация сложных макетов, часто достигая самых современных результатов. Ключевым отличием является широкий спектр специализации. Некоторые модели, такие как Llama-3.1-Nemotron-Nano-VL и H2OVL-Mississippi-800M, узкоспециализированы для анализа документов, обеспечивая замечательную точность распознавания и контроля качества документов. Другие, такие как InternVL3, Qwen 2.5-VL и MiniCPM-V-4, представляют собой универсальные мультимодальные модели, которые обладают высокими возможностями распознавания текста, но предназначены для гораздо более широкого круга

задач, включая визуальное мышление, понимание видео и графический интерфейс взаимодействие. Это отражает стратегический выбор между передовым опытом в конкретной предметной области и широкими мультимодальными возможностями. Наконец, в тексте подчеркивается важнейшая роль эффективности и доступности. Ведется активная работа по внедрению этих мощных моделей на периферийных устройствах. Такие модели, как PaddleOCR, MiniCPM-V-4 и RolmOCR, явно оптимизированы для снижения потребления ресурсов, благодаря квантованным версиям и поддержке таких платформ, как vLLM, что позволяет использовать их в реальных приложениях на потребительском оборудовании. Эта тенденция гарантирует, что преимущества продвинутого искусственного интеллекта не ограничиваются облачными системами, а становятся все более доступными для обработки на устройстве.

1.4 Обнаружение элементов документа

DocLayout-YOLO

DocLayout-YOLO — это специализированная версия YOLOv10, дополненная модулем управляемой обработки данных от глобального к локальному (GL-CRM) для адаптивной обработки объектов различного масштаба. Он наследует однопроходную архитектуру CNN от YOLO, поддерживая высокую скорость обнаружения и повышая точность при верстке документов [13]. Модель была предварительно обучена на большом синтетическом наборе данных DocSynth-300K (~300 000 искусственно сгенерированных страниц), затем доработана на реальных наборах данных, включая DocLayNet и DocStructBench [13]. В DocLayNet он достигает 79,7 % mAP@0.5:0.95 и 93,4 % AP@50, превосходя базовый показатель YOLOv10 (без обучения работе с документами) на ~3,5 процентных пункта (76.2 %) [13][98]. Выходные данные состоят из координат ограничивающего прямоугольника и меток классов для каждого элемента макета (например, заголовка, абзаца, таблицы, изображения), пригодных для последующего структурирования документа [13]. Исходный код, конфигурации и предварительно обученные веса находятся в открытом доступе в репозитории GitHub [99]. На графическом процессоре NVIDIA A100 DocLayout-YOLO достигает ~85 кадров в секунду, обеспечивая хороший баланс между скоростью и точностью и превосходя мультимодальные модели аналогичной точности по задержке вывода [13]. Для вывода требуется один

высокопроизводительный графический процессор; объем видеопамяти сопоставим со стандартными моделями YOLOv10-L и обычно составляет 6-8 ГБ [13]. Модель основана исключительно на визуальных особенностях макета документа, что делает ее не зависимой от языка и применимой к документам на любом языке, не требуя распознавания текста или лингвистической адаптации [13].

LayoutLMv3

LayoutLM v3 — это третья итерация мультимодальной модели Microsoft для искусственного интеллекта документов, объединяющая токены из распознанного текста и фрагменты визуальных изображений в рамках единой системы Vision Transformer backbone (ViT-B) [100]. В отличие от LayoutLM v1/v2, визуальные элементы извлекаются непосредственно из transformer без отдельного CNN, что упрощает архитектуру и улучшает взаимодействие текста и изображения. Предварительное обучение проводилось на базе данных IIT-CDIP (~42 миллиона страниц) с использованием единой задачи одновременного маскирования слов и вставок ("унифицированная маскировка текста и изображений") [100]. Дополнительный вариант, LayoutLMv3-BC, был доработан для китайских документов, чтобы улучшить производительность на этом языке [100]. Базовая модель выводит скрытые представления токенов и исправлений. Для анализа макета документа (DLA) авторы обучили каскадную R-CNN-головку. Однако готовая к использованию головка обнаружения не входит в стандартные реализации Transformers, для чего требуется пользовательский код или скрипты из репозитория на базе Detectron2 [101]. Исходный код доступен в репозитории Microsoft UniLM на GitHub [101]; предварительно подготовленные веса (базовый, большой и BC-варианты) размещены на Hugging Face [102]. Производительность: в PubLayNet LayoutLM v3 в сочетании с Cascade R-CNN обеспечивает mAP @ 0,5:0,95 = 95,1 % (AP50 = 95,8 %) [100], превосходя DiT-base (94,5 %) [10]. В DocStructBench он достигает AP50 ≈92 % при ~9 кадрах в секунду на A100 [13]. Полный конвейер (OCR + LayoutLM v3 + детектор) требует ~9 ГБ памяти графического процессора и работает со скоростью ~9 кадров в секунду на Tesla A100 [13], что значительно медленнее, чем у легких детекторов на базе YOLO (>80 кадров в секунду). Языковая поддержка: производительность зависит от языка предварительной подготовки и точности распознавания. Базовая модель оптимизирована для английского языка; вариант BC

улучшает результаты при работе с китайскими документами. При точном распознавании модель может обрабатывать другие сценарии [100].

Промежуточный вывод

DocLayout-YOLO и LayoutLMv3 представляют собой два разных подхода к анализу макета документа. DocLayout-YOLO - это быстрая, основанная на визуализации модель, адаптированная из YOLOv10, дополненная модулем глобального и локального контекста для лучшей обработки многомасштабных элементов. Он работает с данными из синтетических и реальных документов и обеспечивает высокую точность при высокой скорости — около 85 кадров в секунду на графическом процессоре A100. Он работает исключительно с визуальными функциями, что делает его независимым от языка и пригодным для работы с документами на любом языке без необходимости распознавания или обработки текста. Он требует 6-8 ГБ памяти графического процессора и выводит ограничивающие рамки и метки классов для таких элементов макета, как текст, таблицы и изображения.

В отличие от этого, LayoutLMv3 - это мультимодальная модель, которая объединяет визуальную и текстовую информацию, используя основу Vision Transformer. Она использует распознавание текста для извлечения текстовых маркеров, которые затем объединяются с фрагментами изображений для общего понимания. Предварительно обработанный на миллионах страниц документов, он обеспечивает очень высокую точность — 95,1 % отображения в публичной сети — особенно в сочетании с каскадной головкой R-CNN. Однако полный конвейер работает медленнее (около 9 кадров в секунду) и требует больше ресурсов (~9 ГБ памяти графического процессора). Он оптимизирован для английского языка, имеется специальная версия (BC) для китайского, а производительность зависит от качества распознавания текста.

Таким образом, DocLayout-YOLO идеально подходит для быстрого, не зависящего от языка определения макета, где главное - скорость и простота. LayoutLMv3 обеспечивает более высокую точность за счет сочетания текста и визуального оформления, но медленнее и сложнее в развертывании. Выбор между ними зависит от варианта использования: эффективность и масштабируемость благоприятствуют DocLayout-YOLO, в то время как глубокое понимание семантики благоприятствует LayoutLMv3.

1.5 Обнаружение и распознание таблиц

Table Transformer

Table Transformer (TATR) — это основанная на DETR модель, разработанная Microsoft для обнаружения таблиц в изображениях документов и анализа их структуры [103]. Модель фактически состоит из двух этапов: на первом определяются границы таблицы, а на втором - отдельные ячейки и их положение в строках и столбцах [103]. TATR был обучен на крупномасштабном наборе данных PubTables-1M (~1 миллион таблиц из научных статей) [104][105], что обеспечило высокую точность: вариант DETR, обученный на этом наборе данных, достиг точности ~99 % и отзыва при IoU > 0,5 [104]. TATR также демонстрирует самую современную производительность в распознавании структуры ячеек без дополнительной тонкой настройки [104]. Официальный репозиторий поддерживает экспорт результатов в HTML или CSV. Предоставляется полный конвейер для преобразования обнаруженных таблиц и их содержимого в эти структурированные форматы [106]. Предварительно подготовленные веса и сценарии вывода/тонкой настройки доступны в открытом доступе. Кодовая база позволяет проводить полные циклы обучения на пользовательских наборах данных [106]. В современном наборе данных ICDAR 2019 современные модели трансформаторов, включая TATR, достигают F1 ≈ 0,96 при IoU = 0,6 [107], превосходя CascadeTabNet (~0,94) [108]. При распознавании структуры ячеек TATR устанавливает новые критерии в Grid F1 и GriTS metrics [104]. Модель обнаружения основана на ResNet-50 + Transformer (~40-50 миллионов параметров) и работает на графическом процессоре с объемом видеопамяти ≥4-8 ГБ. Процессорный вывод также поддерживается, хотя и медленнее. TATR работает исключительно с визуальными и геометрическими подсказками. Текст в ячейках извлекается с помощью внешнего распознавателя текста (например, Tesseract) [3], что делает модель не зависимой от языка и применимой к таблицам на любом языке. Решаемые задачи: обнаружение таблиц, распознавание структуры таблиц (обнаружение ячеек, идентификация строк/столбцов), сквозной анализ таблиц.

UniTable

UniTable — это новая унифицированная модель для сквозного распознавания таблиц по изображениям, разработанная при участии Microsoft Research Asia [109]. В отличие от традиционных каскадных подходов, UniTable использует один преобразователь для

одновременного извлечения структуры таблицы, содержимого ячеек и точных координат ячеек [109]. Обучение проводилось в два этапа: (1) предварительное обучение под самостоятельным контролем на миллионах изображений таблиц без меток, за которым следовало (2) доработка на аннотированных наборах данных, включая PubTabNet, FinTabNet, SynthTabNet, PubTables-1M и ICDAR-2019 [109]. Модель доступна в двух компактных вариантах (параметры ~30 м и ~125 м). Исходный код, предварительно подготовленные весы и демонстрационный блокнот опубликованы в открытом доступе [110]. Модель поддерживает адаптацию к предметной области и может быть успешно адаптирована для специализированных случаев использования [109]. UniTable установил новые передовые результаты по четырем из пяти основных критериев распознавания таблиц [109]. Например, на ICDAR-2019 (Modern, structure) он получил взвешенный показатель F1 в 42,6 балла, значительно превысив предыдущий лучший показатель в 24,8. На PubTabNet он получил оценку TEDS в 97,9 % (по сравнению с 97,2 %). Компания также достигла показателей ≈96,5 % в FinTabNet и ≈98,9 % в SynthTabNet, приблизившись к предельному уровню качества. Примечательно, что UniTable не требует внешнего распознавания текста или извлечения текста в формате PDF — он распознает текст в ячейках непосредственно с изображения [109]. Модель генерирует последовательность токенов, описывающую таблицу HTML, что позволяет легко преобразовать ее в форматы HTML или JSON [109]. Даже версия с большим объемом 125 миллионов параметров эффективно работает на одном графическом процессоре с 8 ГБ видеопамяти, обрабатывая страницу за несколько секунд. Модель в основном была обучена на данных на английском языке. Хотя распознавание структуры таблиц не зависит от языка, встроенное распознавание текста лучше всего работает с латиницей и цифрами.

Сравнение моделей Table Detection

Представленная информация описывает разнообразный и быстро развивающийся ландшафт технологий распознавания текста и искусственного интеллекта для обработки документов, начиная от традиционных модульных систем и заканчивая передовыми комплексными мультимодальными моделями. Анализ показывает четкую дихотомию между двумя доминирующими парадигмами. Первая парадигма представлена модульными моделями, ориентированными на конкретные задачи, такими как DocLayout-YOLO, LayoutLMv3, Table Transformer (TATR) и UniTable. Эти модели узкоспециализированы и

ориентированы на выполнение конкретных подзадач, таких как определение структуры или разбор таблиц. Они часто используют каскадный подход, при котором одна модель обнаруживает элементы (например, таблицу), а другая анализирует ее структуру. Их сила заключается в точности и эффективности; например, DocLayout-YOLO обеспечивает высокий FPS, в то время как UniTable устанавливает новые стандарты SOTA. Эти модели, как правило, не зависят от языка, полагаются на визуальные возможности и часто требуют внешнего распознавания текста для извлечения текста. Они идеально подходят для приложений, где высокая точность при выполнении конкретной задачи имеет первостепенное значение. Вторая, и все более доминирующая, парадигма определяется унифицированными комплексными мультимодальными LLM, такими как Donut, GOT, olmOCR, dots.ocr и PP-ChatOCRv4 от PaddleOCR. Эти модели представляют собой фундаментальный сдвиг, поскольку они используют единую масштабную модель vision-language для обработки изображения всего документа и непосредственного создания структурированных выходных данных, таких как JSON или Markdown, за один проход. Такой целостный подход позволяет им понимать контекст, поддерживать правильный порядок чтения и обрабатывать сложные макеты более эффективно, чем модульные системы. Это настоящие модели для понимания документов, способные выполнять несколько задач одновременно. Однако за это приходится платить: они значительно больше по размеру, требуют больше ресурсов и работают медленнее, чем их модульные аналоги. Таким образом, отрасль разделяется на два стратегических направления. С одной стороны, наблюдается тенденция к высокоточному проектированию с использованием легких, быстрых и специализированных моделей, которые превосходно справляются с отдельными компонентами конвейера распознавания текста. С другой стороны, наблюдается мощное движение в сторону когнитивной интеграции с использованием крупных универсальных моделей, которые нацелены на воспроизведение понимания документов человеком. Выбор между этими парадигмами зависит от области применения: модульные модели оптимальны для высокопроизводительных, экономичных или встраиваемых систем, в то время как комплексные виртуальные машины (VLM) лучше всего подходят для комплексного анализа документов с учетом контекста, где ключевым является целостное понимание.

2 Экспериментальные исследования

Для поиска остиального решения по распознанию тесты для основных решений и задач были проведены экспериментальные исследования. Эксперименты по каждой группе задач описаны в советующем разделе.

2.1 Распознание и детекция текста

В этой работе использовались наборы данных FUNSD и XFUND для печатного текста, отобранные на основе их доступности, качества аннотаций и языковой поддержки. Наборы данных были выбраны из-за их разнообразия и репрезентативности для задач распознавания печатного текста и OCR. Более подробная информация о каждом наборе данных представлена ниже.

Датасет FUNSD представляет из себя формы в отсканированных документах с помехами — набор данных из 199 отсканированных формуляров на английском языке (например, анкет, заявлений) с аннотациями на уровне токенов и графиками соотношения ключ-значение. Его небольшой размер и строгие рекомендации по аннотациям делают его удобным "золотым стандартом" для оценки, хотя и ограничивают возможности улучшения показателей при точной настройке.

Датасет XFUND является многоязычным расширением FUNSD, содержащим 1393 заполненных формы на семи языках: китайском, японском, испанском, французском, итальянском, немецком и португальском. В нем сохранена та же схема аннотаций — разметка на уровне токенов и соотношения ключ-значение. Французский подмножество часто содержит рукописный текст, и маркерами списка (маркеры) иногда аннотированной как отдельные ограничительные рамки, которые могут уменьшить, обнаружения и сделать достижение высоких показателей сложнее.

По результатам экспериментов лучше всего для задачи детекции текста показала себя модель DocTR: db_mobilnet_v3_large опередив остальные решения, таблица 2.1.

Таблица 2.1 — F1@50 метрика для задачи обнаружения текста, английский язык для датасета FUNSD, для остальных языков XFUND,

Язык	F1@50				
	EasyOCR: CRAFT	PaddleOCR ch_pp-ocrv4_det	PaddleOCR ch_pp ocrv4_det_server	DocTR: db_mobilnet_ v3_large	Tesseract V5
EN	0.472	0.670	0.675	0.853	0.580
DE	0.803	0.874	0.867	0.941	0.729
FR	0.752	0.787	0.781	0.901	0.630
ES	0.776	0.815	0.845	0.932	0.676
ZH	0.780	0.792	0.791	0.171	0.285
JA	0.672	0.651	0.662	0.197	0.389
IT	0.709	0.771	0.787	0.912	0.657
PT	0.685	0.772	0.759	0.901	0.680

После эксперимента на детекцию проводилась серия экспериментов по самым популярным фреймворкам, библиотекам и самими известными языковыми моделями для OCR. Эксперименты показали превосходство Qwen 2.5-vl-7b, таблицы 2.2 и 2.3. Данная модель либо лидирует на отдельно взятом языке, либо незначительно отстает от лидера, при этом в среднем для разных языков выдавая наилучшее качество.

Таблица 2.2 — Нормализованный CER для классических решений для базового набора моделей

	Нормализованный CER									
Язык	Easy OCR: CRNN	Paddle OCR: ch_pp-ocrv4_rec	Paddle OCR: ch_pp-ocrv4_rec_server	Paddle OCR: ch_pp-ocrv4_rec_server_rec_doc	Doc TR: parseq	Tesseract V5	GotOCR2	Rolmocr-7b	Qwen2-vl-ocr-2b-instruct	**Qwen2.5-VL-7B-Instruct**
EN	0.297	0.137	0.130	0.129	0.915	0.191	0.109	0.038	0.153	0.040
DE	0.040	0.094	0.092	0.072	0.501	0.057	0.073	0.038	0.252	0.056
FR	0.106	0.104	0.107	0.104	0.517	0.114	0.098	0.042	0.223	0.107
ES	0.039	0.090	0.081	0.099	0.468	0.057	0.082	0.034	0.210	0.067
ZH	0.130	0.058	0.035	0.052	0.978	0.210	0.103	0.030	0.165	0.043
JA	0.268	0.313	0.201	0.828	0.975	0.276	0.367	0.072	0.295	0.069
IT	0.081	0.080	0.070	0.044	0.529	0.075	0.104	0.055	0.213	0.055
PT	0.056	0.085	0.111	0.071	0.555	0.081	0.083	0.032	0.188	0.031

Таблица 2.3 — Нормализованный WER для классических решений для базового набора моделей

	Нормализованный WER									
Язык	Easy OCR: CRNN	Paddle OCR: ch_pp-ocrv4_rec	Paddle OCR: ch_pp-ocrv4_rec_server	Paddle OCR: ch_pp-ocrv4_rec_server_rec_doc	Doc TR: pars eq	Tess eract V5	GotOCR2	Rolm ocr-7b	Qwen2-vl-ocr-2b-instruct	**Qwen2.5-VL-7B-Instruct**
EN	0.535	0.393	0.394	0.395	0.982	0.325	0.243	0.084	0.240	0.056
DE	0.075	0.227	0.216	0.334	0.650	0.124	0.237	0.051	0.289	0.161
FR	0.213	0.335	0.311	0.440	0.621	0.217	0.307	0.101	0.280	0.311
ES	0.114	0.297	0.303	0.433	0.629	0.130	0.289	0.060	0.245	0.207
ZH	0.390	0.135	0.111	0.094	0.992	0.398	0.221	0.100	0.283	0.120
JA	0.612	0.589	0.489	0.907	0.976	0.586	0.702	0.259	0.530	0.255
IT	0.153	0.234	0.385	0.134	0.642	0.127	0.279	0.092	0.259	0.091
PT	0.145	0.307	0.460	0.275	0.712	0.134	0.253	0.071	0.257	0.073

После базового набора экспериментов по распознаванию текстов было принято решение провести дополнительные эксперименты с различными большими языковыми моделями. А также с различными по весу и квантизации модификациями хорошо зарекомендовавшего себя Qwen. В силы значительной вычислительной сложности было принято провести предварительные испытания всего на двух языках, для фильтрации и отбора лидеров для последующих более детальных тестов. В результате эксперимента по различным размерам Qwen, таблица 2.4, не было замечено значительного роста качества с увеличением размера модели, более того даже версия на 3B параметров показала себя конкурентной.

Таблица 2.4 — Эксперименты на распознание текста для различных размеров Qwen 2.5 vl Instruct

Язык	Вес модели, миллиарды параметров	Тип квантизации	CER_{norm}	WER_{norm}
EN	3	-	0.040	0.073
	3	AWQ	0.060	0.086
	7	-	0.040	0.056
	7	AWQ	0.057	0.065
	32	-	0.039	0.072
	32	AWQ	0.063	0.097
	72	AWQ	0.049	0.076
ZH	3	-	0.021	0.120
	3	AWQ	0.037	0.121
	7	-	0.069	0.255
	7	AWQ	0.038	0.119
	32	-	0.042	0.139
	32	AWQ	0.058	0.158
	72	AWQ	0.039	0.115

Для сравнения с Qwen были отобраны еще 15 различных моделей, специализирующихся на распознании текста. При это на отдельно взятом запуске некоторые модели все же обгоняли Qwen, и ни одна не обошла сразу на двух языках по качеству, таблица 2.4.

Таблица 2.4 — Эксперименты на распознание текста для различных больших языковых моделей

Язык	Название	Вес модели, миллиарды параметров	CER_{norm}	WER_{norm}
EN	InternVL3	8	0.085	0.118
		14	0.096	0.124
	Ovis2	4	0.035	0.057
		8	0.060	0.068
	Ovis2.5	2	0.041	0.074
		9	0.063	0.113
	MiniCPM-V-4	4	0.068	0.097
	Qwen2-VL	7	0.045	0.076
	InternVL2	1	0.408	0.465
	JackChew-Qwen2-VL	2	0.690	0.712
	Gemma-3	12	0.468	0.479
	aya-vision	8	0.267	0.358
	MiMo-VL-7B-RL	7	0.037	0.076
	dots.ocr	4	0.385	0.399
	idefics3-8b-llama3	8	0.365	0.545
ZH	InternVL3	8	0.078	0.180
		14	0.050	0.164
	Ovis2	4	0.057	0.130
		8	0.054	0.118
	Ovis2.5	2	0.043	0.126
		9	0.056	0.171
	MiniCPM-V-4	4	0.048	0.152
	Qwen2-VL	7	0.038	0.131
	InternVL2	1	0.170	0.276
	JackChew-Qwen2-VL	2	0.436	0.549
	Gemma-3	12	0.549	0.897
	aya-vision	8	0.786	0.901
	MiMo-VL-7B-RL	7	0.045	0.146
	dots.ocr	4	0.375	0.463
	idefics3-8b-llama3	8	0.877	0.952

Таким образом после проведения комплексных исследований по распознанию текста можно прийти к выводу, что Qwen занимает лидирующее положение именно в задачи распознания текста среди open source решений для мультиязычных датасетов и сканов.

2.3 Распознание таблиц

В рамках экспериментальных исследований проводились тесты по распознанию таблиц с их структурой. Эксперименты проводились для больших языковых моделей и фреймворка unitable. При этом проводилось две группы: по распознанию таблиц в формате Markdown (md) и в формате html, таблица 2.5. Для html также оценивалась метрика TEDS позволяющая понять качество распознанной структуры (чем выше, тем лучше). Unitable изначально парсит таблицы в html и не представляется возможным поменять его вывод.

Таблица 2.5 — Результаты задачи распознания таблиц с помощью больших языковых моделей на датасете SciTSR

Модель	md	html	
	WER_{norm}	TEDS	WER_{norm}
Qwen2.5-VL-3B-Instruct	0.137	0.806	0.175
Qwen2.5-VL-3B-Instruct-AWQ	0.224	0.759	0.169
Qwen2.5-VL-7B-Instruct	0.121	0.867	0.110
Qwen2.5-VL-7B-Instruct-AWQ	0.127	0.899	0.125
Qwen2.5-VL-32B-Instruct	0.114	0.863	0.093
Qwen2.5-VL-32B-Instruct-AWQ	0.108	0.872	0.107
Qwen2.5-VL-72B-Instruct-AWQ	0.098	0.903	0.071
InternVL3-8B	0.131	0.792	0.065
InternVL3-14B	0.160	0.865	0.106
Ovis2-8B	0.128	0.876	0.119
aya-vision-8b	0.440	0.308	0.426
MiMo-VL-7B-RL	0.270	0.762	0.197
dots.ocr	0.380	0.595	0.989
idefics3-8b-llama3	0.979	0.218	0.608
Unitable	-	0.970	0.296

В итоге хоть Unitable и демонстрирует наилучшее распознание структуры таблицы, но решения на основе больших языковых моделей демонстрирую значительный перевес в качестве распознания текста, при этом на мультиязычных таблицах разница только усилится. Как и в случае мультиязычного распознания наилучшие результаты показали модели семейства Qwen, при этом Qwen 2.5 7b сохраняет позицию баланса между качеством и стоимостью инференса.

2.4 Распознание документов end2end

И последняя группа экспериментов, проводимая в рамках данного исследования посвящена распознанию скана целиком, то есть задача формулируется как вывести весь текст с отсканиронного документа в порядке чтения. При этом важно отметить что в выбранном датасете для экспериментов встречается достаточно много ошибок в разметки, поэтому достижения 100 % не представляется возможным, а для сравнения можно использовать относительные величины, таблица 2.6.

Таблица 2.6 — Метрики end2end распознания документов на датасете DocBank

Модель	CER_{norm}	WER_{norm}
Qwen2.5-VL-3B-Instruct	0.412	0.452
Qwen2.5-VL-3B-Instruct-AWQ	0.445	0.445
Qwen2.5-VL-7B-Instruct	0.332	0.476
Qwen2.5-VL-7B-Instruct-AWQ	0.313	0.418
Qwen2.5-VL-32B-Instruct	0.451	0.554
Qwen2.5-VL-32B-Instruct-AWQ	0.513	0.620
Qwen2.5-VL-72B-Instruct-AWQ	0.258	0.369
InternVL3-8B	0.376	0.477
InternVL3-14B	0.990	1.088
Ovis2-8B	0.313	0.403
aya-vision-8b	3.754	3.677
MiMo-VL-7B-RL	0.697	0.919
dots.ocr	0.383	0.423
idefics3-8b-llama3	0.886	0.955

По результатам экспериментов появляются модели, конкурирующие за лидерство с Qwen, но при этом в контексте мультиязычного распознания и распознания таблиц, Qwen остается все еще более привлекательным вариантом, так как в сканах встречается много таких задач.

2.5 Выводы

На основе всех проведенных экспериментов можно сделать вывод, что с точки зрения распознания мультиязычных документов, понимания эх структуры, парсинга таблиц лидирующее место занимает семейство моделей Qwen 2.5 при этом версия 7b видится

оптимальной с точки зрения производительности, качества и стоимости инференса. Ее сравнительно небольшой вес позволяет запускать ее даже на потребительских карточках, что значительно упрощает использование.

3 Диссеминация проекта

Ссылки на исходный код веб-сервиса: https://github.com/Industrial-AI-Research-Lab/documentor

Таблица 3.1 – Ресурсы, на которых выполнялась популяризация проекта

Ресурс	Название	Ссылка
GitHub	Программная документация и руководство пользователя	https://github.com/Industrial-AI-Research-Lab/documentor/blob/main/README.md

ЗАКЛЮЧЕНИЕ

В ходе этой работы был проведен целенаправленный обзор литературы и многоцелевое экспериментальное исследование, включающее обнаружение/распознавание текста, анализ структуры документа, понимание таблиц и сквозной синтаксический анализ. В литературе четко прослеживаются две парадигмы: (i) модульные конвейеры распознавания текста (детектор → распознаватель → постобработка) и (ii) сквозные модели языка распознавания (VLM), которые совместно считывают и обрабатывают информацию. Выбор зависит от приложения: модульные стеки отличаются высокой скоростью и экономичностью или встроенными настройками, в то время как VLM обеспечивают более глубокое целостное понимание, когда контекст и структура имеют наибольшее значение. Наш обзор охватывает универсальные методы и конкретные задачи, перечисленные в отчете (текст, структура, таблицы), обеспечивая сравнительную основу для последующих экспериментов.

Для обнаружения и распознавания печатного текста мы использовали FUNSD (англоязычные бланки с надписями на уровне токенов) и многоязычное расширение XFUND (семь языков, аналогичная схема надписей). Эти наборы данных были выбраны из-за качества и широты аннотаций, и они остаются общими “критериями” для распознавания документов. В нашем тесте обнаружения детектор DocTR db_mobilenet_v3_large достиг максимального значения F1@50 для всех языков в FUNSD/XFUND в нашей настройке.

По общему признанию, VLM, особенно Qwen—2.5-VL, доминировали на рынке с точки зрения соотношения цены и качества. Среди открытых моделей Qwen-2.5-VL-7B (AWQ) обеспечил наилучший баланс в наших тестах (например, CERnorm 0.313, WERnorm 0.418), в то время как более крупные варианты Qwen улучшили абсолютное качество при более высоких вычислениях (например, 72B-AWQ: CERnorm 0.258, WERnorm 0.369). Несколько альтернативных вариантов были конкурентоспособны по подмножествам (например, Ovis2-8B, InternVL3-8B), но Qwen оставался более безопасным по умолчанию для многоязычных документов.

При работе с таблицами результаты распределяются между структурой и текстом: индикатор Unitable указывает на структурную точность, однако VLMS обеспечивает заметно лучшую точность текста; мы ожидаем, что преимущество VLM расширится при многоязычном сканировании с расширенным набором таблиц. Следовательно, Qwen-2.5-

VL остается нашей предпочтительной основой при внедрении таблиц в различные контексты документов.

Далее мы выполнили сквозной анализ страниц в DocBank, измерив нормализованный CER/WER по порядку чтения всей страницы. Учитывая известные помехи при маркировке в выбранном разделении, результаты сравниваются в относительном выражении; тем не менее, ранжирование соответствовало результатам для каждой задачи, что подтверждает выбор Qwen-2.5-VL в качестве основного семейства моделей.

С инженерной точки зрения, в рамках проекта была создана практичная библиотека с открытым исходным кодом DocuMentor — вместе с конвейером анализа документов, ориентированным на производство, на базе Qwen-2.5. Реализованный конвейер охватывает PDF-файлы, сканирование и интеграцию в DocuMentor для последующей автоматизации (аналитика, RAG, нормализация). Ссылки на источники и подробности распространения приведены в отчете; библиотека и экспериментальные ресурсы находятся в открытом доступе.

В целом, совокупность данных, полученных из обзора литературы и экспериментов, показывает, что для понимания многоязычных документов — обеспечения баланса между качеством распознавания текста, работой с таблицами, структурными рассуждениями и затратами на логический вывод — семейство Qwen-2.5 на сегодняшний день является наиболее эффективным открытым решением. В частности, Qwen-2.5-VL-7B предлагает отличное соотношение цены и качества, оставаясь при этом доступным для развертывания на обычных графических процессорах, что упрощает внедрение в реальных условиях в DocuMentor.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Roboflow. Best OCR Models for Text Recognition (Benchmark) [Электронный ресурс] // Roboflow Blog. – 2025. – URL: https://blog.roboflow.com/best-ocr-models-text-recognition/ (дата обращения: 07.05.2025).

2. Papers With Code. PubTabNet Benchmark (Table Recognition) [Электронный ресурс] – URL: https://paperswithcode.com/sota/table-recognition-on-pubtabnet (дата обращения: 08.05.2025).

3. Smith R. An Overview of the Tesseract OCR Engine [Электронный ресурс] // Proc. ICDAR. – 2007. – URL: https://tesseract-ocr.github.io/tessdoc/The_Tesseract_OCR_Engine.html (дата обращения: 07.05.2025).

4. Clanuwat C., Bober-Irizar M., Yamamoto K. и др. Deep Learning for Classical Japanese Literature [Электронный ресурс] // Nature Machine Intelligence. – 2020. – URL: https://www.nature.com/articles/s42256-019-0133-5 (дата обращения: 07.05.2025).

5. Reddy Y. The Ultimate Guide to Assessing Table Extraction [Электронный ресурс] // Nanonets Blog. – 2024. – URL: https://nanonets.com/blog/the-ultimate-guide-to-assessing-table-extraction/ (дата обращения: 07.05.2025).

6. Kim G., Paek S., Oh S. и др. Donut: Document Understanding Transformer without OCR [Электронный ресурс] // ECCV Proc. – 2022. – URL: https://arxiv.org/abs/2111.15664 (дата обращения: 07.05.2025).

7. Melo G. Fine-tuning Donut Transformer for Document Classification [Электронный ресурс] // Qantev Blog. – 2024. – URL: https://www.qantev.com/post/fine-tuning-donut-transformer-for-document-classification (дата обращения: 07.05.2025).

8. Hugging Face. naver-clova-ix/donut-base-finetuned-rvlcdip — Model Card [Электронный ресурс]. – URL: https://huggingface.co/naver-clova-ix/donut-base-finetuned-rvlcdip (дата обращения: 07.05.2025).

9. NAVER CLOVA AI Research. Donut [Электронный ресурс]: репозиторий GitHub. – 2022. – URL: https://github.com/clovaai/donut (дата обращения: 07.05.2025).

10. Li X., Cui S., Yu X. и др. DiT: Self-Supervised Pre-training for Document Image Transformer [Электронный ресурс] // arXiv. – 2022. – URL: https://arxiv.org/abs/2210.06158 (дата обращения: 07.05.2025).

11. Microsoft Research. DiT: Document Image Transformer [Электронный ресурс]: репозиторий GitHub. – 2022. – URL: https://github.com/microsoft/dit (дата обращения: 07.05.2025).
12. Microsoft Research. microsoft/dit-base-960k [Электронный ресурс]: модель на Hugging Face Hub. – 2022. – URL: https://huggingface.co/microsoft/dit-base-960k (дата обращения: 07.05.2025).
13. Zhao Z., Yang P., Liu Y. и др. DocLayout-YOLO: Enhancing Document Layout Analysis through Diverse Synthetic Data and Global-to-Local Adaptive Perception [Электронный ресурс] // arXiv. – 2024. – URL: https://arxiv.org/abs/2410.12628 (дата обращения: 07.05.2025).
14. Wei H., Xu Y., Li X. и др. General OCR Theory: Towards OCR-2.0 via a Unified End-to-end Model [Электронный ресурс] // arXiv. – 2024. – URL: https://arxiv.org/abs/2409.01704 (дата обращения: 07.05.2025).
15. Wei H. GOT-OCR2.0 [Электронный ресурс]: репозиторий GitHub. – 2024. – URL: https://github.com/Ucas-HaoranWei/GOT-OCR2.0 (дата обращения: 07.05.2025).
16. Liao M., Wan Z., Yao C. и др. Real-time Scene Text Detection with Differentiable Binarization [Электронный ресурс] // arXiv. – 2020. – URL: https://arxiv.org/abs/1911.08947 (дата обращения: 07.05.2025).
17. Ye P., Xiao B., Sun J. и др. PP-Structure: A Document AI Framework for Structured Document Understanding [Электронный ресурс] // arXiv. – 2021. – URL: https://arxiv.org/abs/2105.01848 (дата обращения: 07.05.2025).
18. PaddlePaddle. PaddleOCR Documentation: Release v2.9 and Pipelines [Электронный ресурс]. – 2025. – URL: https://paddlepaddle.github.io/PaddleOCR/main/en/index.html (дата обращения: 08.05.2025).
19. PaddleX Documentation. Universal Layout Analysis v2 Pipeline Tutorial [Электронный ресурс]. – 2025. – URL: https://paddlepaddle.github.io/PaddleX/latest/en/pipeline_usage/tutorials/ocr_pipelines/layout_parsing_v2.html (дата обращения: 08.05.2025).
20. PaddlePaddle. PaddleOCR [Электронный ресурс]: репозиторий GitHub. – 2023. – URL: https://github.com/PaddlePaddle/PaddleOCR (дата обращения: 07.05.2025).
21. PaddleOCR Developers. PaddleOCR: Multilingual Support and PP-OCRv3 [Электронный ресурс] // Baidu Research Blog. – 2022. – URL:

https://paddlepaddle.github.io/PaddleOCR/main/en/ppocr/blog/multi_languages.html (дата обращения: 07.05.2025).
22. Li C., Guo R., Zhou J. и др. PP-StructureV2: A Stronger Document Analysis System [Электронный ресурс] // arXiv. – 2022. – URL: https://arxiv.org/abs/2210.05391 (дата обращения: 08.05.2025).
23. QwenLM. Qwen2.5-VL [Электронный ресурс]: репозиторий GitHub. – 2025. – URL: https://github.com/QwenLM/Qwen2.5-VL (дата обращения: 07.05.2025).
24. Yin Z., Zhang Z., Dong L. и др. Qwen-VL: A Versatile Vision-Language Model with Frozen Visual Encoder [Электронный ресурс] // arXiv. – 2024. – URL: https://arxiv.org/abs/2402.08060 (дата обращения: 07.05.2025).
25. Zhu M., Zhang J., Fu W. и др. Qwen2.5-VL: Technical Report [Электронный ресурс] // arXiv. – 2025. – URL: https://arxiv.org/abs/2502.13923 (дата обращения: 07.05.2025).
26. Reducto AI. RolmOCR: A Faster, Lighter Open Source Document OCR Model [Электронный ресурс] // Reducto AI Blog. – 2025. – URL: https://reducto.ai/blog/introducing-rolmocr-open-source-ocr-model (дата обращения: 07.05.2025).
27. Allen Institute for AI. olmOCR: Open-Source OCR for Accurate Document Conversion [Электронный ресурс]. – 2025. – URL: https://olmocr.allenai.org/ (дата обращения: 07.05.2025).
28. Zhu J., Wang W., Chen Z. и др. InternVL3: Exploring Advanced Training and Test-Time Recipes for Open-Source Multimodal Models // arXiv, 2025. — № 2504.10479. — Режим доступа: https://arxiv.org/abs/2504.10479 (дата обращения: 27.08.2025).
29. InternVL3 — официальный блог-анонс OpenGVLab от 11.04.2025. — Режим доступа: https://internvl.github.io/blog/2025-04-11-InternVL-3.0/ (дата обращения: 27.08.2025).
30. Introduction of InternVL 3.0 Series — документация InternVL (ReadTheDocs). — Режим доступа: https://internvl.readthedocs.io/en/latest/internvl3.0/introduction.html (дата обращения: 27.08.2025).
31. Chat Data Format — руководство по форматам разметки/грандированию (ReadTheDocs). — Режим доступа:

https://internvl.readthedocs.io/en/latest/get_started/chat_data_format.html (дата обращения: 27.08.2025).
32. Deploy InternVL 3 Series — руководство по развёртыванию (LMDeploy/OpenAI API совместимость). — Режим доступа: https://internvl.readthedocs.io/en/latest/internvl3.0/deployment.html (дата обращения: 27.08.2025).
33. Quick Start of InternVL 3.0 Series — размеры весов, режимы загрузки (bf16/8-бит/4-бит). — Режим доступа: https://internvl.readthedocs.io/en/latest/internvl3.0/quick_start.html (дата обращения: 27.08.2025).
34. OpenGVLab/InternVL — репозиторий GitHub (новости, ссылки на модели и отчёты). — Режим доступа: https://github.com/OpenGVLab/InternVL (дата обращения: 27.08.2025).
35. OpenGVLab/InternVL3-8B — карточка модели на Hugging Face (Apache-2.0). — Режим доступа: https://huggingface.co/OpenGVLab/InternVL3-8B (дата обращения: 27.08.2025).
36. InternVL-Chat API — описание публичного API. — Режим доступа: https://internvl.readthedocs.io/en/latest/get_started/internvl_chat_api.html (дата обращения: 27.08.2025).
37. InternVL3 — коллекция моделей/ресурсов на Hugging Face. — Режим доступа: https://huggingface.co/collections/OpenGVLab/internvl3-67f7f690be79c2fe9d74fe9d (дата обращения: 27.08.2025).
38. Lu, S.; Li, Y.; Chen, Q.-G. и др. Ovis: Structural Embedding Alignment for Multimodal Large Language Model // arXiv, 2024. — № 2405.20797. — [Электронный ресурс]. URL: https://arxiv.org/abs/2405.20797 (дата обращения: 27.08.2025).
39. AIDC-AI. Ovis: GitHub-репозиторий проекта. — [Электронный ресурс]. URL: https://github.com/AIDC-AI/Ovis (дата обращения: 27.08.2025).

40. AIDC-AI. Ovis1.6-Gemma2-9B — карточка модели на Hugging Face. — [Электронный ресурс]. URL: https://huggingface.co/AIDC-AI/Ovis1.6-Gemma2-9B (дата обращения: 27.08.2025).
41. AIDC-AI. Ovis2-1B — карточка модели на Hugging Face (серия Ovis 2: 1B–34B). — [Электронный ресурс]. URL: https://huggingface.co/AIDC-AI/Ovis2-1B (дата обращения: 27.08.2025).
42. Lu, S.; Li, Y.; Xia, Y. и др. Ovis 2.5 Technical Report // arXiv, 2025. — № 2508.11737. — [Электронный ресурс]. URL: https://arxiv.org/abs/2508.11737 (дата обращения: 27.08.2025).
43. Wang, G.H.; Lu, S.; Li, Y. и др. Ovis-U1 Technical Report // arXiv, 2025. — № 2506.23044. — [Электронный ресурс]. URL: https://arxiv.org/abs/2506.23044 (дата обращения: 27.08.2025).
44. AIDC-AI. Ovis2.5-9B — карточка модели на Hugging Face. — [Электронный ресурс]. URL: https://huggingface.co/AIDC-AI/Ovis2.5-9B (дата обращения: 27.08.2025).
45. Modal Labs. How much VRAM do I need for LLM inference? — 2024. — [Электронный ресурс]. URL: https://modal.com/blog/how-much-vram-need-inference (дата обращения: 27.08.2025).
46. Gemma Team; Google DeepMind. Gemma 3 Technical Report // arXiv, 2025. — № 2503.19786. — [Электронный ресурс]. URL: https://arxiv.org/abs/2503.19786 (дата обращения: 27.08.2025)
47. Farabet, C.; Warkentin, T. Introducing Gemma 3: The most capable model you can run on a single GPU or TPU // The Keyword (Google Blog), 12.03.2025. — [Электронный ресурс]. URL: https://blog.google/technology/developers/gemma-3/ (дата обращения: 27.08.2025).

48. Google AI for Developers. Gemma 3 model overview, 14.08.2025 (обнов.). — [Электронный ресурс]. URL: https://ai.google.dev/gemma/docs/core (дата обращения: 27.08.2025).
49. Google AI for Developers. ShieldGemma 2 — model card, 03.04.2025. — [Электронный ресурс]. URL: https://ai.google.dev/gemma/docs/shieldgemma/model_card_2 (дата обращения: 27.08.2025).
50. Google AI for Developers. Function calling with Gemma, 21.03.2025. — [Электронный ресурс]. URL: https://ai.google.dev/gemma/docs/capabilities/function-calling (дата обращения: 27.08.2025).
51. Google AI for Developers. Gemma — Releases (Gemma 3n, 270M и др.), 14.08.2025 (обнов.). — [Электронный ресурс]. URL: https://ai.google.dev/gemma/docs/releases (дата обращения: 27.08.2025).
52. Hugging Face. google/gemma-3-27b-it — модель и условия доступа, 11.08.2025. — [Электронный ресурс]. URL: https://huggingface.co/google/gemma-3-27b-it (дата обращения: 27.08.2025).
53. Databricks. Announcing Google’s Gemma 3 on Databricks, 14.07.2025. — [Электронный ресурс]. URL: https://www.databricks.com/blog/announcing-googles-gemma-3-databricks (дата обращения: 27.08.2025).
54. Google Developers Blog. Introducing Gemma 3 270M, 14.08.2025. — [Электронный ресурс]. URL: https://developers.googleblog.com/en/introducing-gemma-3-270m/ (дата обращения: 27.08.2025).
55. NVIDIA. Llama-3.1-Nemotron-Nano-VL-8B-V1 — карточка модели на Hugging Face, 03.06.2025. — [Электронный ресурс]. URL: https://huggingface.co/nvidia/Llama-3.1-Nemotron-Nano-VL-8B-V1 (дата обращения: 27.08.2025).

56. NVIDIA. Llama-3.1-Nemotron-Nano-VL-8B-V1 — Model Card, Build.NVIDIA.com, 03.06.2025. — [Электронный ресурс]. URL: https://build.nvidia.com/nvidia/llama-3.1-nemotron-nano-vl-8b-v1 (дата обращения: 27.08.2025).
57. NVIDIA NGC. Llama 3.1 Nemotron Nano VL 8B V1 — NIM-контейнер, 30.06.2025. — [Электронный ресурс]. URL: https://catalog.ngc.nvidia.com/orgs/nim/teams/nvidia/containers/llama-3.1-nemotron-nano-vl-8b-v1 (дата обращения: 27.08.2025).
58. NVIDIA Developer Blog. New NVIDIA Llama Nemotron Nano Vision Language Model Tops OCR Benchmark for Accuracy, 03.06.2025. — [Электронный ресурс]. URL: https://developer.nvidia.com/blog/new-nvidia-llama-nemotron-nano-vision-language-model-tops-ocr-benchmark-for-accuracy/ (дата обращения: 27.08.2025).
59. Hugging Face Blog. Welcome the NVIDIA Llama Nemotron Nano VLM to Hugging Face, 27.06.2025. — [Электронный ресурс]. URL: https://huggingface.co/blog/nvidia/llama-nemotron-nano-vl (дата обращения: 27.08.2025).
60. NVIDIA NeMo Framework. Llama Nemotron Nano VL 8B — руководство по импорту и запуску, 2025. — [Электронный ресурс]. URL: https://docs.nvidia.com/nemo-framework/user-guide/latest/vlms/llama_nemotron_vl.html (дата обращения: 27.08.2025).
61. LLM-Core Team Xiaomi. MiMo-VL Technical Report // arXiv, 2025. — № 2506.03569. — [Электронный ресурс]. URL: https://arxiv.org/abs/2506.03569 (дата обращения: 27.08.2025).
62. XiaomiMiMo. MiMo-VL-7B-RL — карточка модели на Hugging Face (MIT). — [Электронный ресурс]. URL: https://huggingface.co/XiaomiMiMo/MiMo-VL-7B-RL (дата обращения: 27.08.2025).

63. XiaomiMiMo. MiMo-VL — репозиторий GitHub (README, обновление 2508; Apache-2.0). — [Электронный ресурс]. URL: https://github.com/XiaomiMiMo/MiMo-VL (дата обращения: 27.08.2025).
64. XiaomiMiMo. MiMo-VL-7B-RL-2508 — карточка модели на Hugging Face (обновлённые метрики). — [Электронный ресурс]. URL: https://huggingface.co/XiaomiMiMo/MiMo-VL-7B-RL-2508 (дата обращения: 27.08.2025)
65. XiaomiMiMo. MiMo-VL — коллекция моделей на Hugging Face. — [Электронный ресурс]. URL: https://huggingface.co/collections/XiaomiMiMo/mimo-vl-68382ccacc7c2875500cd212 (дата обращения: 27.08.2025)
66. rednote-hilab. dots.ocr — модель на Hugging Face. — [Электронный ресурс]. URL: https://huggingface.co/rednote-hilab/dots.ocr (дата обращения: 27.08.2025).
67. rednote-hilab. dots.ocr — репозиторий GitHub. — [Электронный ресурс]. URL: https://github.com/rednote-hilab/dots.ocr (дата обращения: 27.08.2025).
68. rednote-hilab. dots.ocr — демо-страница. — [Электронный ресурс]. URL: https://dotsocr.xiaohongshu.com/ (дата обращения: 27.08.2025).
69. Docker Hub. rednotehilab/dots.ocr — официальный образ (vLLM OpenAI API). — [Электронный ресурс]. URL: https://hub.docker.com/r/rednotehilab/dots.ocr (дата обращения: 27.08.2025).
70. helizac. dots.ocr-4bit — квантизованный чекпойнт (NF4). — [Электронный ресурс]. URL: https://huggingface.co/helizac/dots.ocr-4bit (дата обращения: 27.08.2025).
71. H2O.ai. H2OVL-Mississippi-800M — модель на Hugging Face (Apache 2.0). — 2025. — URL: https://huggingface.co/h2oai/h2ovl-mississippi-800m (дата обращения: 27.08.2025).

72. Galib, S.; Wang, S.; Xu, G.; Pfeiffer, P.; Chesler, R.; Landry, M.; Ambati, S. H2OVL-Mississippi Vision Language Models: Technical Report // arXiv, 2024. — № 2410.13611. — URL: https://arxiv.org/abs/2410.13611 (дата обращения: 27.08.2025).
73. H2O.ai. Document Classification with H2O VL Mississippi — A Quick Guide // Офиц. блог H2O.ai, 28.10.2024. — URL: https://h2o.ai/blog/2024/document-classification-with-h2o-vl-mississippi--a-quick-guide/ (дата обращения: 27.08.2025).
74. Business Wire. H2O.ai Launches New Multimodal Foundation Models to Undertake Document AI Use Cases — пресс-релиз, 17.10.2024. — URL: https://www.businesswire.com/news/home/20241017716438/en/H2O.ai-Launches-New-Multimodal-Foundation-Models-to-Undertake-Document-AI-Use-Cases (дата обращения: 27.08.2025).
75. H2O.ai. H2OVL Mississippi — продуктовая страница. — 2025. — URL: https://h2o.ai/platform/mississippi/ (дата обращения: 27.08.2025).
76. Hugging Face. «h2ovl-mississippi-800m — Discussions»: запуск на CPU. — 2024. — URL: https://huggingface.co/h2oai/h2ovl-mississippi-800m/discussions (дата обращения: 27.08.2025).
77. OpenBMB. MiniCPM-o-2_6 — карточка модели на Hugging Face. — 2025. — [Электронный ресурс]. URL: https://huggingface.co/openbmb/MiniCPM-o-2_6 (дата обращения: 27.08.2025).
78. OpenBMB. MiniCPM-o 2.6: A GPT-4o Level MLLM for Vision, Speech and Multimodal Live Streaming on Your Phone — блог-страница. — 24.01.2025. — [Электронный ресурс]. URL: https://openbmb.vercel.app/minicpm-o-2-6-en (дата обращения: 27.08.2025).
79. OpenBMB. MiniCPM-o — репозиторий GitHub (документация, примеры, поддержка vLLM/Ollama/llama.cpp). — 2025. — [Электронный ресурс]. URL:

https://github.com/OpenBMB/MiniCPM-o (дата обращения: 27.08.2025).
80. OpenBMB. MiniCPM-o-2_6-gguf — веса в формате GGUF (llama.cpp). — 2025. — [Электронный ресурс]. URL: https://huggingface.co/openbmb/MiniCPM-o-2_6-gguf (дата обращения: 27.08.2025).
81. OpenBMB. MiniCPM-V-4 — карточка модели на Hugging Face. — [Электронный ресурс]. URL: https://huggingface.co/openbmb/MiniCPM-V-4 (дата обращения: 27.08.2025).
82. Yao, Y.; Yu, T.; Zhang, A. и др. MiniCPM-V: A GPT-4V Level MLLM on Your Phone // arXiv, 2024. — № 2408.01800; см. также: Nat. Commun. 16, 5509 (2025). — [Электронный ресурс]. URL: https://arxiv.org/abs/2408.01800 (дата обращения: 27.08.2025).
83. MiniCPM Team и др. MiniCPM4: Ultra-Efficient LLMs on End Devices // arXiv, 2025. — № 2506.07900. — [Электронный ресурс]. URL: https://arxiv.org/abs/2506.07900 (дата обращения: 27.08.2025).
84. OpenBMB. MiniCPM-V — репозиторий/страница серии на Hugging Face (новости, билингвальность, демо). — [Электронный ресурс]. URL: https://huggingface.co/openbmb/MiniCPM-V (дата обращения: 27.08.2025).
85. OpenBMB. MiniCPM-V-4 — страница модели для Ollama. — [Электронный ресурс]. URL: https://ollama.com/openbmb/minicpm-v4 (дата обращения: 27.08.2025)
86. Allen AI. olmOCR [Электронный ресурс]: репозиторий GitHub. – 2025. – URL: https://github.com/allenai/olmocr (дата обращения: 07.05.2025).
87. Allen Institute for AI. Poznanski J., Borchardt J., Dunkelberger J. и др. olmOCR: Unlocking Trillions of Tokens in PDFs with Vision Language Models [Электронный ресурс] // arXiv. – 2025. – URL: https://arxiv.org/abs/2502.18443 (дата обращения: 07.05.2025).
88. Reducto. RolmOCR [Электронный ресурс]: репозиторий Hugging Face. – 2025. – URL: https://huggingface.co/reducto/RolmOCR (дата обращения: 07.05.2025).

89. Baek Y., Lee B., Han D. и др. CRAFT: Character-Region Awareness for Text Detection [Электронный ресурс] // arXiv. – 2019. – URL: https://arxiv.org/abs/1904.01941 (дата обращения: 07.05.2025).
90. JaidedAI. EasyOCR: Ready-to-use OCR with 80+ Supported Languages [Электронный ресурс]: репозиторий GitHub. – 2023. – URL: https://github.com/JaidedAI/EasyOCR (дата обращения: 07.05.2025).
91. Lauar F. Spanish TrOCR: Leveraging Transfer Learning for Language Adaptation [Электронный ресурс] // Medium. – 2024. – URL: https://medium.com/qantev/spanish-trocr-leveraging-transfer-learning-for-language-adaptation-0864a51dfbf3 (дата обращения: 07.05.2025).
92. Tesseract-ocr. Tesseract Open Source OCR Engine [Электронный ресурс]: репозиторий GitHub. – 2023. – URL: https://github.com/tesseract-ocr/tesseract (дата обращения: 07.05.2025).
93. Anitha R., Rajeev R. R., Nazeem M., Navaneeth S. Open-Source OCR Libraries: A Comprehensive Study for Low Resource Language [Электронный ресурс] // Proc. ICON-2024. – 2024. – URL: https://aclanthology.org/2024.icon-1.48.pdf.
94. Agarwal N. Replacing Google-OCR With Tesseract and Saving Thousands in Monthly Billings [Электронный ресурс] // Medium. – 2021. – URL: https://medium.com/swlh/replacing-google-ocr-with-tesseract-and-saving-thousands-in-monthly-billings-63839e9cfd0a (дата обращения: 07.05.2025).
95. Li M., Yao T., Chen K. и др. TrOCR: Transformer-based Optical Character Recognition with Pre-trained Models [Электронный ресурс] // arXiv. – 2023. – URL: https://arxiv.org/abs/2109.10282 (дата обращения: 07.05.2025).
96. Mindee. docTR: Document Text Recognition (v0.5) [Электронный ресурс]. – 2023. – URL: https://mindee.github.io/doctr/ (дата обращения: 07.05.2025).
97. GitHub Discussion. docTR half-precision – accuracy and speed benchmark #1385 [Электронный ресурс]. – Nov 2023. – URL: https://github.com/mindee/doctr/discussions/1385 (дата обращения: 08.05.2025).
98. Wang A., Zhang C., Ye Y. и др. YOLOv10: Real-Time End-to-End Object Detection [Электронный ресурс] // arXiv. – 2024. – URL: https://arxiv.org/abs/2405.14458 (дата обращения: 07.05.2025).

99. OpenDataLab. DocLayout-YOLO [Электронный ресурс]: репозиторий GitHub. – 2024. URL: https://github.com/opendatalab/DocLayout-YOLO (дата обращения: 07.05.2025).
100. Huang Y., Yang Z., Chen K. и др. LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking [Электронный ресурс] // arXiv. – 2022. – URL: https://arxiv.org/abs/2204.08387 (дата обращения: 07.05.2025).
101. Microsoft Research. LayoutLMv3: Unified Document AI Repository [Электронный ресурс]: репозиторий GitHub. – 2022. – URL: https://github.com/microsoft/unilm/tree/master/layoutlmv3 (дата обращения: 07.05.2025).
102. Hugging Face. microsoft/layoutlmv3-base — Pre-trained LayoutLMv3 Model [Электронный ресурс]. – URL: https://huggingface.co/microsoft/layoutlmv3-base (дата обращения: 07.05.2025).
103. Pramanik A., Sarkar M., Lu A. и др. Table Transformer: A Structure-Aware Sequence-to-Sequence Model for Table Recognition [Электронный ресурс] // arXiv. – 2021. – URL: https://arxiv.org/abs/2207.09405 (дата обращения: 07.05.2025).
104. Smock J., Zhong X., Gao J. и др. PubTables-1M: Towards Comprehensive Table Extraction from Scientific Articles [Электронный ресурс] // Proc. CVPR. – 2022. – URL: https://openaccess.thecvf.com/content/CVPR2022/html/Smock_PubTables-1M_Towards_Comprehensive_Table_Extraction_From_Scientific_Articles_CVPR_2022_paper.html (дата обращения: 07.05.2025).
105. Microsoft Research. PubTables-1M Dataset [Электронный ресурс]: репозиторий GitHub. – 2022. – URL: https://github.com/microsoft/table-transformer/tree/main/dataset (дата обращения: 07.05.2025).
106. Microsoft Research. table-transformer [Электронный ресурс]: репозиторий GitHub. – 2023. – URL: https://github.com/microsoft/table-transformer (дата обращения: 07.05.2025).
107. Kasem M. S., Mahmoud M., Yagoub B. HTTD: A Hierarchical Transformer for Accurate Table Detection in Document Images [Электронный ресурс] // Mathematics. – 2025. – URL: https://www.mdpi.com/2227-7390/13/2/266 (дата обращения: 08.05.2025).
108. Prasad D., Gadpal A., Kapadni K. и др. CascadeTabNet: An Approach for End-to-End Table Detection and Structure Recognition from Image-Based Documents [Электронный ресурс] // arXiv. – 2020. – URL: https://arxiv.org/abs/2004.12629 (дата обращения: 08.05.2025).

109. Peng H., Duan N., Liu X. и др. UniTable: A Unified Model for Table Structure and Cell Text Recognition [Электронный ресурс] // arXiv. – 2024. – URL: https://arxiv.org/abs/2403.04822 (дата обращения: 07.05.2025).
110. poloclub. UniTable [Электронный ресурс]: репозиторий GitHub. – 2024. – URL: https://github.com/poloclub/unitable (дата обращения: 07.05.2025).