Петрозаводский государственный университет Институт математики и информационных технологий Кафедра информатики и математического обеспечения

09.04.02 Информационные системы и технологии

Отчет о практике по научно-исследовательской работе

Детекция границ таблиц и изображений на сканах и изображениях

(промежуточный)

Выполнил:
студент 5 курса группы 22505

Хаухия Александр Владимирович _____
подпись

Место прохождения практики:
Кафедра информатики и математического обеспечения

Период прохождения практики:

01.09.2024 - 28.12.2024

Руководитель:
Кулаков Кирилл Александрович, к.ф.-м.н,, доцент

_____
подпись

Итоговая оценка

_____
оценка

Петрозаводск — 2025

Оглавление

Введение....3

1. Анализ решений детекции таблиц....4

2. Методы детекции изображений и встроенных объектов в документах....6

Заключение....7

Список литературы....8

Введение

Цель практики: изучение методов и алгоритмов определения границ и структуры таблиц и встроенных изображений в документе

Задачи практики:

1. Анализ решений детекции таблиц на сканах и изображений.
2. Методы детекции изображений и встроенных объектов в документах.

В наше время технологии OCR (Optical Character Recognition) пользуются большой популярностью в различных сферах жизни человека. С помощью данных технологий решается огромное количество задач: обработка сканов, текстов и изображений, распознавание текста для последующего перевода или анализа, распознавание и оцифровка рукописей, старинных документов и другие задачи. Технологии OCR активно внедряются в российских компаниях. Они позволяют ускорить обработку документов, снизить количество ошибок и автоматизировать рутинные процессы. В данной работе будет использоваться одно из направлений OCR – Table Detection and Recognition.

OCR помогает людям экономить время и деньги. Существуют множество готовых решений в задаче OCR, Table Detection, Table Recognition и Layout. Такие модели умеют читать текст на многих языках, таких как арабский, китайский, японский, умеют распознавать структуры различных таблиц, которые бывают с границами и без, с простой структурой и сложной и так далее, умеют определять порядок чтения документа, приближенный к логике восприятия человеком.

Актуальность темы связана с активным переходом организаций на цифровые документы, где важную роль играет автоматизация в сканировании документов.

На данный момент первый этап написания научно-исследовательской работы направлен на изучение и анализ материалов по тематике работы.

1. Анализ решений детекции таблиц

Первая задача – это анализ существующих подходов и решений по детекции таблиц на сканированных документах и изображениях. Таблицы – ключевой элемент множества документов: от бухгалтерской отчётности и медицинских карт до академических статей. Их корректное распознавание необходимо для последующего анализа, извлечения и использования данных и информации.

На данный момент существуют два основных подхода к этой задаче: классические методы компьютерного зрения и современные нейросетевые решения. Ниже представлены примеры из этих категорий.

Перед тем как переходить к классическим методам, стоит написать о базовых операциях, которые используются в этих решениях:

1. Пороговая бинаризация или Thresholding. Этот метод позволяет преобразовать изображение в чёрно-белый формат для упрощения последующей обработки. Подходит для фотографий таблиц, так как чаще всего они имеют разноцветную палитру.
2. Морфологические операции. Операции сжатия и расширения позволяют выделить горизонтальные и вертикальные линии на скане.
3. Детектор прямых линий или Hough Line Transform. Этот метод позволяет обнаружить линии путём преобразования в параметрическое пространство.
4. Поиск контуров. Как и предыдущий метод, позволяет рассмотреть потенциальные ячейки таблицы или её границы.

Выше перечисленные методы можно найти в библиотеке Python «OpenCV». Они применяются как к изображениям различных форматов, так и к PDF-документам. Ниже предоставлены классические методы, использующие эти операции:

1. Camelot, использует бинаризацию и морфологию для выделения линий (границ таблиц), пересечения и контуры для сетки и ячеек таблицы. Все методы написаны с использованием OpenCV;
2. Pdfplumber, в нём структуру таблиц можно определить по встроенным геометрическим правилам;
3. Custom Pipeline OpenCV, можно самому создать детектор таблиц, используя библиотеку OpenCV;
4. Tesseract, до 4 версии включительно, также был сделан на базовых операциях и некоторые его функции позволяли сканировать таблицы, однако они не позволяли извлекать таблицу в виде структурированных данных [1].

Эти методы были популярны до 2017-2018 года, после появились первые нейросетевые подходы, использующие CNN и FCN архитектуры для сегментации строк и столбцов таблиц.

Современные методы основываются на моделях глубокого обучения и показывают высокую точность даже на сложных данных. Вот некоторые из самых эффективных решений:

1. TableNet (2018), одна из первых моделей, использующая CNN-архитектуру encoder-decoder для сегментации таблиц;
2. CascadeTabNet (2020), каскадная модель на основе Mask R-CNN, позволяющая точно определять и таблицы, и ячейки;
3. TATR (2021) – это инновационная модель, предложенная Facebook, нацеленная на понимание логической структуры таблиц, а не просто детекцию. Она преобразует таблицы в абстрактное представление, что делает возможным последующую обработку и анализ;
4. С 2022-2024 развивается новое поколение моделей, нацеленные на Layout детекцию. Они умеют находить и классифицировать текст, таблицы, изображения, графики и сохранять их в исходном варианте. К таким моделям относятся Donut и LayoutLMv2/3.

Таким образом можно заметить эволюцию моделей, специализирующихся на детекции таблиц и OCR в целом. На данный момент продолжается развитие Layout детекции, в которую также входит распознавание структуры таблиц. Трансформерные и нейросетевые модели обладают лучшей детекцией и распознаванием, но требуют значительных вычислительных ресурсов и времени для их работы и обучения.

Подводя итоги анализа можно сделать следующие выводы:

1. Детекция таблиц – важный этап OCR-систем, особенно при работе с документами строгой структуры;
2. Классические методы подходят для простых случаев и остаются востребованными благодаря своей скорости и доступности;
3. Нейросетевые модели обеспечивают высокую точность на реальных данных и уже внедряются в коммерческие решения;
4. Существует множество доступных инструментов от OpenCV до LayoutLMv3, позволяющих решить задачу под разные бюджеты и потребности.

2. Методы детекции изображений и встроенных объектов в документах

Вторая задача – это анализ методов, позволяющих обнаруживать встроенные изображения и графические объекты в отсканированных документах. Такие элементы, как схемы, диаграммы, графики и другие, часто используются в технической, научной и юридической документации. Автоматическая детекция и извлечение позволяет не только повысить точность OCR, но и предотвращается потерю важной информации.

На практике можно встретить следующие типы изображений:

1. Растровые изображения;
2. Диаграммы и графики, в которых может храниться информация;
3. Логотипы, иконки, иллюстрации, к ним можно отнести печати, подписи, либо логотип какой-то компании или организации;
4. Сканы документов или их части.

Ранние методы извлечения изображений из документа основывались на простом анализе цветовых, текстурных и геометрических признаков. Вот основные методы:

1. Анализ цветовых блоков — поиск зон с плотной цветовой насыщенностью, отличающейся от текста;
2. Поиск по краям (edge detection) – использование фильтров для выделения контуров;
3. Выделение прямоугольных областей – алгоритмы, такие как contour detection и bounding box analysis в OpenCV, часто применяются для обнаружения графических вставок.

Такие методы хорошо работают на простых документах, но дают сбои при наличии шума, перекоса, нестандартных макетов или при отсутствии явных границ у изображения.

Современные подходы к детекции изображений и встроенных объектов в документах опираются на модели объектного детектирования, изначально разработанные для распознавания объектов на обычных фотографиях. Эти модели адаптированы под задачи документного анализа и показывают высокую эффективность даже при сложной вёрстке.

Среди них особенно выделяется модель YOLO (You Only Look Once), известная своей высокой скоростью и простотой интеграции. Актуальная версия YOLOv12 поддерживает мультиклассовую детекцию и может быть легко обучена под задачи обнаружения таких объектов, как графики, диаграммы, встроенные изображения и другие элементы документа. Благодаря компактности, быстродействию и открытым инструментам для обучения, YOLO активно применяется в системах реального времени, где необходимо обрабатывать большие объёмы документов с минимальной задержкой [2].

Заключение

В ходе практики были проанализированы современные подходы к детекции и распознаванию изображений и таблиц на сканированных документах. Были рассмотрены как классические методы, так и современные нейросетевые.

Анализ показал, что классические методы всё ещё могут быть актуальными, но они имеют ряд недостатков, таких как слабая устойчивость к шумам и помехам, невозможность детекции сложных таблиц и невысокое качество работы. В свою очередь нейросетевые модели требуют большое количество вычислительных мощностей и времени для обучения этих моделей.

Полученные в ходе работы знания, помогут в написании НИР.

Список литературы

1. Федоров, А. Как GPT-3 работает и почему это важно [Электронный ресурс] // Habr. — 2021. — URL: https://habr.com/ru/articles/546824/ (дата обращения: 03.04.2025).
2. Zhang, J., Lee, Y. Learning and Reasoning with Multimodal Language Models [Электронный ресурс] // arXiv. — 2025. — URL: https://arxiv.org/html/2502.12524v1 (дата обращения: 04.04.2025).